

# Introduction al modelamiento ecológico

*Guillermo G. Torres PhD*

## Instalando paquetes

El primer comando de R que seguro será utilizado es `install.packages`. R solo incluye un set básico de funciones. Debido a la flexibilidad del lenguaje, R permite a los usuarios desarrollar flujos de trabajo específicos los cuales los son organizados en funciones y agrupados como paquetes. Muchas de estas funciones/paquetes estan almacenados en CRAN. Estos paquetes son investigados: chequeados por errores comunes y deben tener una persona que se dedique a mantenerlos. Un paquete puede ser facilmente instalado en R solamente con el nombre. Como ejemplo vamos a instalar el paquete `rafalib` el cual se va a usar para analizar nuestros datos:

```
install.packages("tidyverse")
```

Se puede cargar el paquete en la sesion de R usando la función **require** o **library**:

```
library(tidyverse)
```

Una vez los paquetes hayan sido instalados, éstos solo seran cargados cada vez que se necesiten.

## Aprendiendo lo básico de R

La primera tarea es completar el tutorial `swirl`, con el ánimo de familiarizarse con la sintaxis básica del lenguaje R, dado que en el curso estos temas no serse cubiertos en detalle y se enfocará mas en temas relacionados con estructuras de datos como listas, data frames, vectores numericos, loops-for, como crear funciones y como usar las funciones `apply` y `replicate`, entre otros.

El Tutorial `swirl` enseña a programar en R de manera interactiva directamente sobre la consola de R. Una vez R haya sido instalado, se puede instalar `swirl` y correrlo de la siguiente manera:

```
install.packages("swirl")
library(swirl)
swirl()
```

No obstante, otra alternativa puede ser tomar la clase interactiva de la Code School: Try R. Adicionalmente existen muchos recursos gratis y guías de referencia en internet; por ejemplo:

- Quick-R: Un recurso online que permite ejercitarse en manejo de datos, estadística básica y visualización
- R reference card PDF by Tom Short

Dos cosas claves que se necesitan saber acerca de R es que uno puede obtener información sobre una función utilizando **help** o **?**, de la siguiente manera:

```
?install.packages
help("install.packages")
```

y los caracteres numeral o hash representan comentarios, por lo que el texto que sigue al caracter no será interpretado como código R:

```
# Este es un comentario... Comentarios aqui...
```

## Paths y directorios de trabajo

Cuando se trabaja en R es útil definir y/o conocer el directorio de trabajo `working directory`. Este es el directorio o folder en el cual R guardará y buscarán los archivos por defecto. Uno puede saber cual es el

directorio de trabajo tipeando:

```
getwd()
```

Se puede cambiar el directorio de trabajo usando la función `setwd`, o cambiando a través de RStudio, dando click sobre la pestaña Session.

Al comienzo de cada sesión de trabajo se recomienda definir el directorio o carpeta de trabajo. Si se usa Rstudio, el directorio de trabajo se puede definir yendo a:

- Sesión
  - Definir directorio de trabajo
  - Escojer directorio

En la consola de se puede definir de la siguiente manera:

```
setwd('/direccion/de/la/carpeta/de/trabajo/')
```

## Sobre este curso y sus datos

Los datos que utilizarán en este curso fueron usados en la tesis doctoral de Verneaux (Verneaux et al. 2003). Él propuso que se podían usar algunas especies de peces para caracterizar zonas ecológicas a lo largo de ríos y arroyos en Europa. Verneaux demostró que las comunidades de peces eran buenos indicadores biológicos para estos cuerpos de agua. En este curso vamos a tratar de llegar a la misma conclusión

Los datos consisten en 3 matrices que contienen parte de los datos usados por Verneaux. Estos datos han sido colectados de 30 sitios a lo largo del río *Doubs*, el cual corre entre Francia y Suiza en las montañas Jura. La primera matriz (*spe*) de datos contiene las abundancias de 27 especies de peces, la segunda matriz (*env*) contiene 11 variables ambientales relacionadas con la hidrología, geomorfología y química del río. La tercera matriz (*spa*) contiene las coordenadas geográficas (Cartesianas, X y Y) de los sitios.

## Análisis exploratorio de los datos

Los análisis exploratorios son métodos que usan herramientas de visualización y calcula descriptores sintéticos que son requeridos para ganar información referente a:

- Tener una visión global de los datos
- Transformar o recodificar algunas variables
- Orientar análisis futuros

## Exploración de los datos *Doubs*

Una vez definido el directorio de trabajo vamos a cargar los datos.

```
# Importar los datos desde archivos de texto, ej. formato CSV
# *****
# Matriz de las especies de peces (data frame de las abundancias de los peces):
spe <- read.csv('../data/DoubsSpe.csv', row.names=1)
# Matriz de los datos ambientales:
env <- read.csv('../data/DoubsEnv.csv', row.names=1)
# Matriz de la informacion espacial (Coordenadas geograficas X,Y):
spa <- read.csv('../data/DoubsSpa.csv', row.names=1)
```

Echemos un vistazo a los datos de la comunidad (objeto `spe`, abundancia de los peces)

```
# funciones básicas
# *****
# Muestra el data frame completo (No recomendado para set de datos grandes):
```

```
spe
# Muestra solamente las primeras 5 lineas:
head(spe)

# Muestra la dimensión del data frame (No. filas, No. columnas):
dim(spe)

## [1] 30 27

# Muestra el No. de filas:
nrow(spe)

## [1] 30

# Muestra el No. columnas:
ncol(spe)

## [1] 27

# Muestra solamente 5 filas y 10 columnas:
spe[1:5,1:10]

##   CHA TRU VAI LOC OMB BLA HOT TOX VAN CHE
## 1   0   3   0   0   0   0   0   0   0   0
## 2   0   5   4   3   0   0   0   0   0   0
## 3   0   5   5   5   0   0   0   0   0   0
## 4   0   4   5   5   0   0   0   0   0   1
## 5   0   2   3   2   0   0   0   0   5   2

# Nombre de las columnas (descriptores = especies):
colnames(spe)

## [1] "CHA" "TRU" "VAI" "LOC" "OMB" "BLA" "HOT" "TOX" "VAN" "CHE" "BAR"
## [12] "SPI" "GOU" "BRO" "PER" "BOU" "PSO" "ROT" "CAR" "TAN" "BCO" "PCH"
## [23] "GRE" "GAR" "BBO" "ABL" "ANG"

# Nombre de las filas
rownames(spe)

## [1] "1" "2" "3" "4" "5" "6" "7" "8" "9" "10" "11" "12" "13" "14"
## [15] "15" "16" "17" "18" "19" "20" "21" "22" "23" "24" "25" "26" "27" "28"
## [29] "29" "30"

# Estadísticos descriptivos para las columnas
summary(spe)

##           CHA           TRU           VAI           LOC
## Min.      :0.00   Min.      :0.00   Min.      :0.000   Min.      :0.000
## 1st Qu.:0.00   1st Qu.:0.00   1st Qu.:0.000   1st Qu.:1.000
## Median :0.00   Median :1.00   Median :3.000   Median :2.000
## Mean     :0.50   Mean     :1.90   Mean     :2.267   Mean     :2.433
## 3rd Qu.:0.75   3rd Qu.:3.75   3rd Qu.:4.000   3rd Qu.:4.000
## Max.     :3.00   Max.     :5.00   Max.     :5.000   Max.     :5.000
```

Usando la mediana y la media de las abundancias. Las distribuciones son simétricas?

```
# Distribución general de las abundancias
# *****
```

```

# Mínimo y máximo valor de las abundancias de todo el set de datos:
range(spe)

## [1] 0 5

# Número de especies ausentes
sum(spe==0)

## [1] 435

# Proporción de ceros en el set de datos
sum(spe==0)/(nrow(spe)*ncol(spe))

## [1] 0.537037

# Conteo de especies con 0,1,2,3 o n de abundancia (clases)
ab <- table(unlist(spe))
# Diagrama de barras de la distribución de abundancia de las especies
barplot(ab,las=1,xlab="Clases de abundancia",ylab="Frecuencia",co=gray(5:0/5))

```

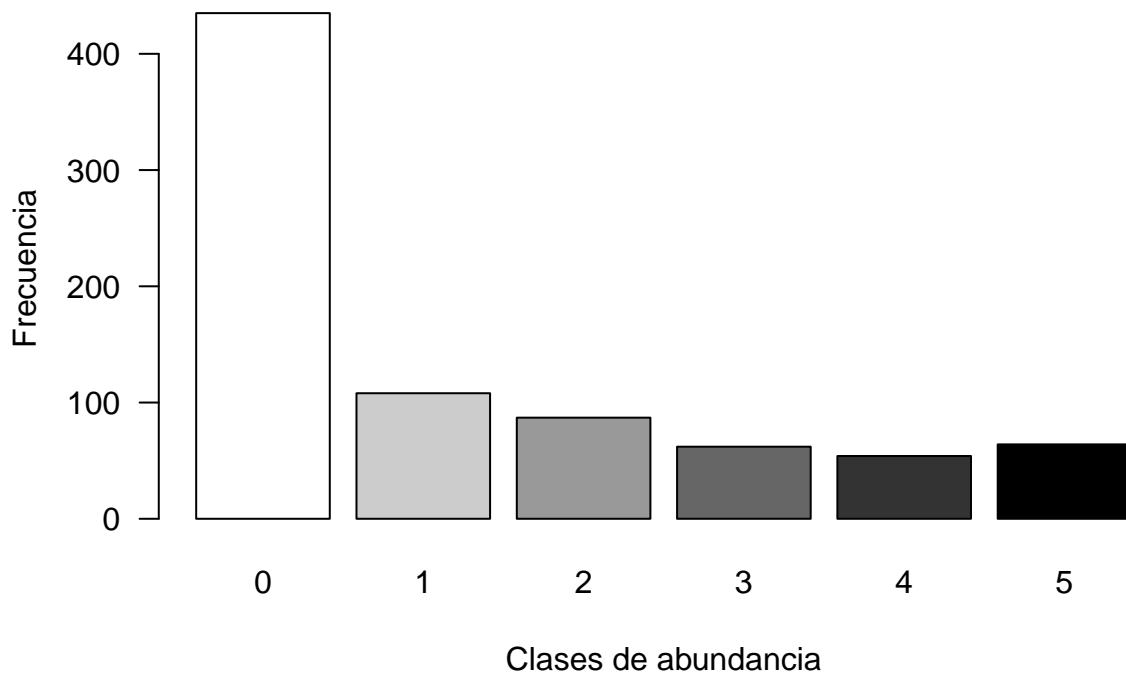


Fig. 1 Diagrama de barras de las clases de abundancia

Mirando el diagrama de barras sobre las clases de abundancia, cómo se interpretaría la alta frecuencia de ceros (ausencias) en el set de datos?

Ahora usemos los datos geograficos para generar una representación gráfica de la ubicacion de los sitios de muestreo.


```

# Mapear la posición de los sitios
# *****
# 1. Creamos un lienzo en blanco donde estarán los puntos de muestreo
plot(spa,type='n',main="Localizacion de los sitios de muestreo",
     xlab="Coordenada X (km)",ylab="Coordenada Y (km)")
# 2. Adicionamos una linea que conecta los puntos de muestreo (simulemos el rio)
lines(spa,col="light blue",lwd=11)

```

```
# 3. Adicionamos los puntos de muestreo
text(spa, rownames(spa),cex=0.8,col="red")
# 4. Adicionamos la direccion del rio
text(50,10,"Corriente arriba",cex=0.8,col="red")
text(30,120,"Corriente abajo",cex=0.8,col="red")
```

## Localizacion de los sitios de muestreo

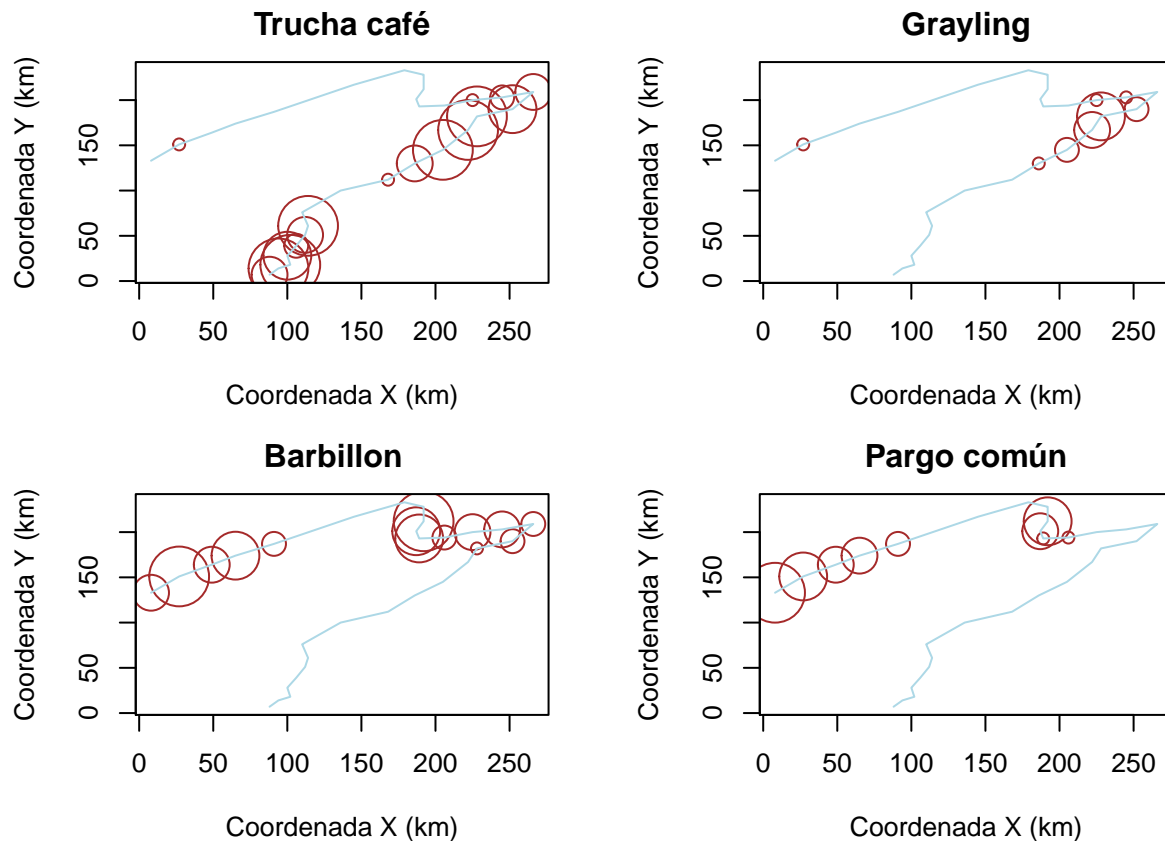


**Fig. 2** Mapa de los 30 sitios de muestreo en el río *Doubs*

Ahora que le hemos dado vida al río ya podemos ubicar los peces y su distribución sobre él. Vamos a plotear algunas de las especies de peces que seleccionó Verneauux. El por qué de estas especies lo veremos más adelante en la guía y tal vez generemos nuevos y más interesantes plots :).

```
# Mapas de las abundancias de algunos de las especies de peces
# *****
# 1. Dividimos la ventana de graficos en 4 (para plotear 4 figuras a la vez)
par(mfrow=c(2,2),mai=c(0.7,0.7,0.4,0.4))
# 2. Ploteamos... (cex es usado para definir el tamaño de algún item en la gráfica)
# Trucha café
plot(spa,col="brown",cex=spe$TRU,main="Trucha café",
      xlab="Coordenada X (km)",ylab="Coordenada Y (km)")
lines(spa,col="light blue",lwd=1)
# Grayling
plot(spa,col="brown",cex=spe$OMB,main="Grayling",
      xlab="Coordenada X (km)",ylab="Coordenada Y (km)")
lines(spa,col="light blue",lwd=1)
# Barber
plot(spa,col="brown",cex=spe$BAR,main="Barbillon ",
      xlab="Coordenada X (km)",ylab="Coordenada Y (km)")
lines(spa,col="light blue",lwd=1)
# Pargo
```

```
plot(spa,col="brown",cex=spe$BCO,main="Pargo común",
     xlab="Coordenada X (km)",ylab="Coordenada Y (km)")
lines(spa,col="light blue",lwd=1)
```



**Fig. 3** Mapa de burbujas de abundancia para cuatro especies de peces

Una información importante es determinar la ocurrencia de las especies en sitios de muestreo. Es decir, lo que queremos responder es: En cuántos sitios de muestreo cada una de las especies de peces aparece?. Aquí vamos a calcular las frecuencias relativas de cada especie y la graficaremos histogramas.

```
# Comparar el número de ocurrencias de las especies
# *****
# 1. Calcular el número de sitios donde cada especie esta presente.
# pista: para sumar por columnas se usa la función apply(), la opción MARGIN se coloca en 2 (ver ?apply)
spe.pres <- apply(spe>0,2,sum)
# 2. Ordenar los resultados en modo creciente
sort(spe.pres)

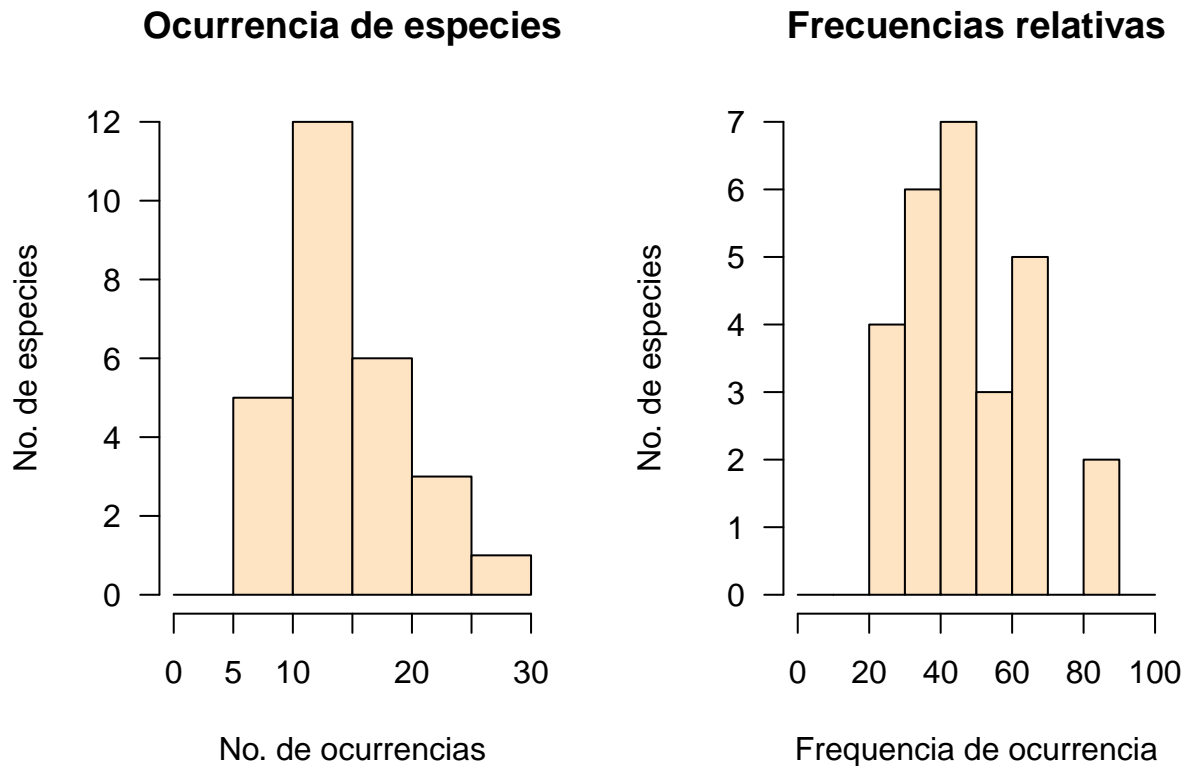
## PCH CHA OMB BLA BCO BBO TOX BOU ROT ANG HOT SPI CAR GRE PSO BAR ABL PER
## 7 8 8 8 9 10 11 11 11 11 12 12 12 12 13 14 14 15
## TRU TAN VAN BRO GAR VAI GOU LOC CHE
## 17 17 18 18 18 20 20 24 25

# 3. Usar porcentaje de frecuencias
spe.relf <- 100*spe.pres/nrow(spe)
# 4 Plotear los histogramas
# Dividimos la ventana gráfica en 2 ventanas horizontales
par(mfrow=c(1,2))
hist(spe.pres,main="Ocurrencia de especies",right=FALSE,las=1,
```

```

xlab="No. de ocurrencias",ylab="No. de especies",
breaks=seq(0,30,by=5),col="bisque")
hist(spe.relf,main="Frecuencias relativas",right=FALSE,las=1,
xlab="Frecuencia de ocurrencia",ylab="No. de especies",
breaks=seq(0,100,by=10),col="bisque")

```



**Fig. 4** Histogramas de frecuencia: ocurrencia de las especies y frecuencia relativa para los 30 sitios de muestreo

Ahora podemos comparar los sitios en función de las especies que ahí se encuentran. Es decir, cuántas especies están presentes en cada sitio de muestreo? (riqueza de especies)

```

# Comparar la riqueza de los sitios de muestreo
# *****
# 1. Calcular el número de especies en cada sitio de muestreo
# pista: para sumar por filas se usa la función apply(), la opción MARGIN se coloca en 1 (ver ?apply)
sit.pres <- apply(spe>0,1,sum)
# 2. Ordenar los resultados en modo creciente
sort(sit.pres)

```

```

## 8 1 2 23 3 7 9 10 11 12 13 4 24 25 6 14 5 15 16 26 30 17 20 22 27
## 0 1 3 3 4 5 5 6 6 6 6 8 8 8 10 10 11 11 17 21 21 22 22 22 22
## 28 18 19 21 29
## 22 23 23 23 26

```

```

# Dividimos la ventana gráfica en 2 ventanas horizontales
par(mfrow=c(1,2))
# 3. Plotear la riqueza de especies vs. la posición de los sitios a lo largo del río
plot(sit.pres,type="s",main="Riqueza de especies vs. \n flujo del río",las=1,
xlab="Posición de los sitios a lo largo del río",ylab="Riqueza en especies",col="grey")
text(sit.pres,row.names(spe),cex=0.8,col="red")

```

```
# 3. Usamos las coordenadas geográficas para graficar un mapa de burbujas usando la riqueza
plot(spa,main="Mapa de riqueza de especies",pch=21,col="black",bg="brown",
     cex=4*sit.pres/max(sit.pres),
     xlab="Coordenada X (km)",ylab="Coordenada Y (km)")
lines(spa,col="light blue")
```




Fig. 5 Plots de la riqueza de especies a lo largo del río

Ahora podemos inspeccionar la diversidad ecológica de los sitios de muestreo mediante los índices clásicos de diversidad. Estos índices serán calculados mediante la funciones que proporciona el paquete Vegan.

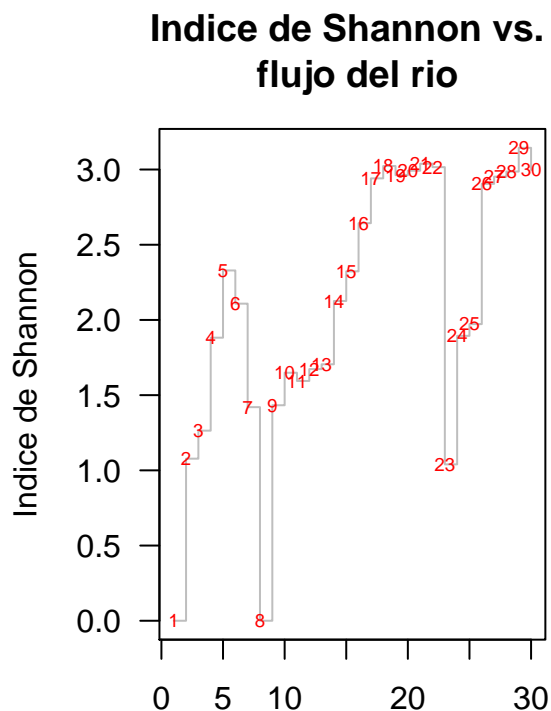
```
# Calcular los índices de biodiversidad
# *****
# 1. Hay que cargar el paquete vegan
library(vegan)
# 2. Riqueza de especies
NO <- rowSums(spe>0)
# 3. Entropía de Shannon
H <- diversity(spe,"shannon")
# 4. No. de especies estimada de Shannon (No de Shanon)
N1 <- exp(H)
# 5. Índice de diversidad de Simpson
S <- diversity(spe,"simpson")
# 6. Índice de diversidad de Simpson
N2 <- diversity(spe,"inv")
# 7. Índice de diversidad de Simpson
N2 <- diversity(spe,"inv")
# 8. Índice de homogeneidad o equitabilidad de Pielou
J <- H/log(NO)
# 9. Homogeneidad de Shannon (proporcion de Hill (Hill's ratio))
```



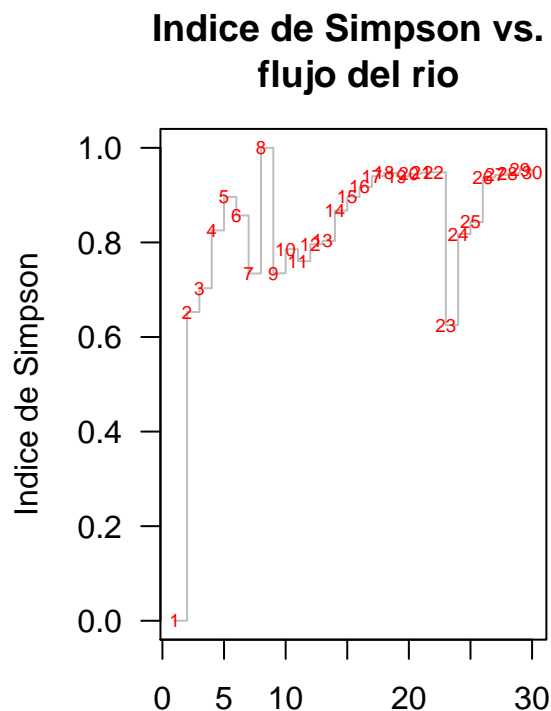
```
E1 <- N1/NO
# 9. Homogeneidad de Simpson
E2 <- N2/NO
div <- data.frame(NO,H,S,N1,N2,E1,E2,J)
head(div)
```

##	NO	H	S	N1	N2	E1	E2	J
## 1	1	0.000000	0.000000	1.000000	1.000000	1.000000	1.000000	NaN
## 2	3	1.077556	0.6527778	2.937493	2.880000	0.9791642	0.9600000	0.9808340
## 3	4	1.263741	0.7031250	3.538634	3.368421	0.8846584	0.8421053	0.9115962
## 4	8	1.882039	0.8253968	6.566883	5.727273	0.8208604	0.7159091	0.9050696
## 5	11	2.329070	0.8961938	10.268387	9.633333	0.9334897	0.8757576	0.9712976
## 6	10	2.108294	0.8571429	8.234184	7.000000	0.8234184	0.7000000	0.9156205

```
par(mfrow=c(1,2))
plot(div$H,type="s",main="Indice de Shannon vs. \n flujo del rio",las=1,
      xlab="Posicion de los sitios a lo largo del rio",ylab="Indice de Shannon",col="grey")
text(div$H,row.names(div$H),cex=0.6,col="red")
plot(div$S,type="s",main="Indice de Simpson vs. \n flujo del rio",las=1,
      xlab="Posicion de los sitios a lo largo del rio",ylab="Indice de Simpson",col="grey")
text(div$S,row.names(div$S),cex=0.6,col="red")
```



Posicion de los sitios a lo largo del rio



Posicion de los sitios a lo largo del rio

#### # Transformación de los datos y normalización

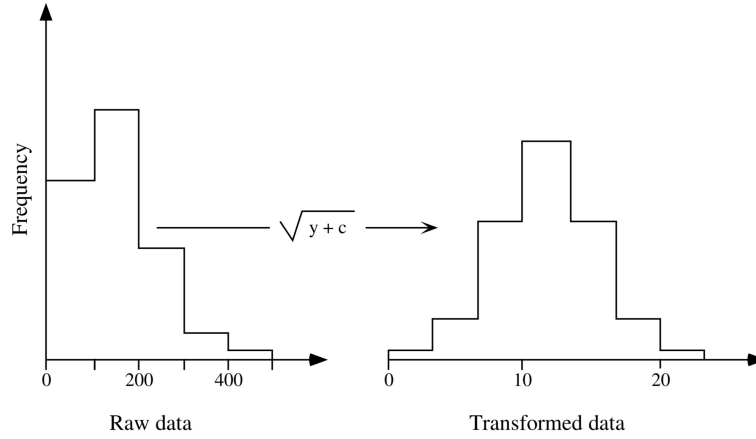
Hay muchas razones por las cuales los datos pueden ser transformados, sin embargo las razones principales pueden ser:

- Si los descriptores (especies) han sido medidos de diferente manera usando unidades diferentes se pueden usar métodos como por ejemplo: rangos, estandarización a z-scores, escalamientos etc.
- Para hacer las variables normales y estables a su varianza se usan métodos como por ejemplo: raíz cuadrada, raíz cuarta, transformaciones logarítmicas etc.

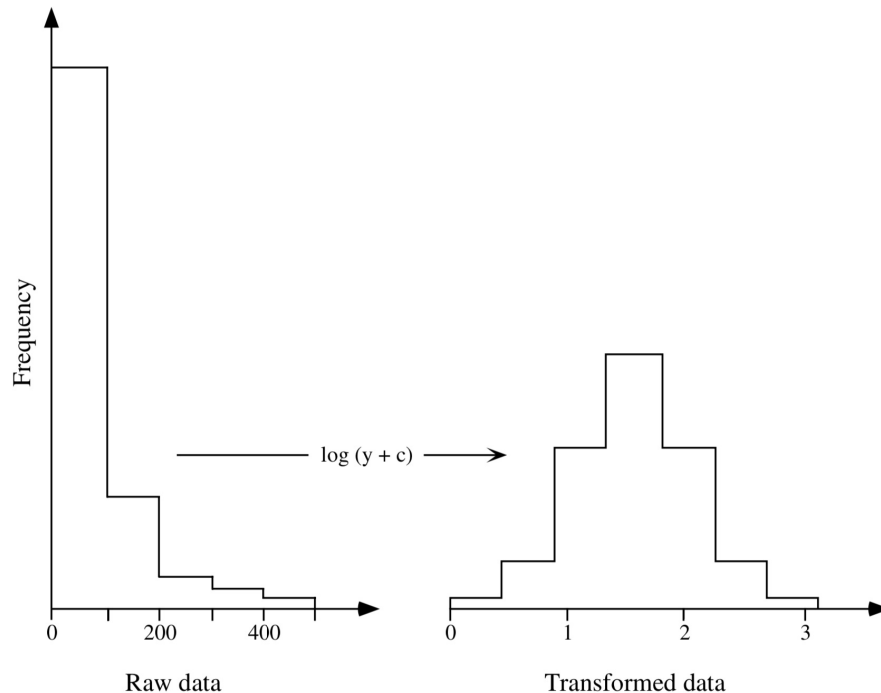
- Para hacer las relaciones entre los descriptores lineales se puede utilizar: transformaciones logarítmicas
- Modificar los pesos de las variables u objetos, por ejemplo: dar la misma longitud (o norma) a todos los vectores objeto
- Recodificar variables categóricas en variables binarias o contrastes de Helmert.

Para nuestro caso, en el que estamos trabajando con abundancia de las especies, la variable abundancia es dimensionalmente homogénea, es decir que expresa o representa la misma unidad física que estamos midiendo. Además, es una variable cuantitativa (ej., conteos, densidad, cobertura, biovolumen, biomasa, frecuencia, etc.) o semi-cuantitativa (clases), y la cual está restringida a valores positivos o nulos (cero, que representa ausencia). Para este tipo de variables algunas simples transformaciones pueden ser llevadas a cabo con el ánimo de reducir la importancia de observaciones con valores demasiado altos, por ejemplo: raíz cuadrada o cuarta o logaritmo natural de la abundancia + 1 ( $\log_1 p$ ; para mantener la ausencia como cero). En casos extremos, para dar el mismo peso a todos los posibles valores de abundancia (sin importar sus valores), los datos pueden ser transformados en binarios, es decir 1 o 0 para sugerir presencia o ausencia.

En casos de datos sesgados (o distribuciones asimétricas) los datos son a menudo transformados aplicando el logaritmo o la raíz cuadrada. La transformación mediante *raíz cuadrada* es la menos drástica y es usada para normalizar datos que tienen una distribución Poisson, donde la varianza es igual a la media (Fig. 6), mientras que las transformaciones *logarítmicas* se aplican a datos que se apartan de una distribución normal (Fig. 7).



**Fig. 6** Transformación raíz cuadrada para normalizar datos con una distribución que tiende a ser Poisson



**Fig. 7** Transformación logarítmica para normalizar una distribución que tiende a apartarse de una distribución Normal

A este tipo de transformaciones las llamaremos estandarizaciones de los datos ecológicos, y en R se puede usar la función **decostand()** del paquete **Vegan** para hacer dichas estandarizaciones. Lo interesante de **decostand** es que las estandarizaciones no se hacen individualmente sino que se tiene en cuenta los otros valores del set de datos. Estas transformaciones pueden ser echas relativas a los sitios, especies o ambos. La elección de sobre que será relativa la estandarización dependerá del enfoque del análisis, veamos:

```
# Transformación y estandarización de los datos
#####
# Transformaciones simples
# *****
# 1. Presencia ausencia
spe.pa <- decostand(spe,method="pa")
# 2. Raíz cuadrada de los datos
spe.sqrt <- sqrt(spe)
# 3. Logaritmo de la abundancia+1
spe.log1p <- log1p(spe)

# Perfil de las especies
# *****
# Escalamiento de las abundancias con respecto al máximo de la especie
# (abundancia/abund.max.de cada especie)
# Notar que MARGIN=2 (relativo a columnas, en este caso las especies)
spe.scal <- decostand(spe,"max",MARGIN=2)
# 3. Escalar las abundancias dividiendo por el No. total de especies
spe.relsp <- decostand(spe,"total",MARGIN=2)

# Perfil de los sitios
# *****
# 1. escalar abundancias dividiendolas por el total de los sitios
# (abundancia relativa por sitio)
```

```

spe.rel <- decostand(spe,"total",MARGIN=1)
# si el escalamiento funcionó, la suma de las abundancias para cada sitio sera?
# pista: apply(spe.rel,1,sum)

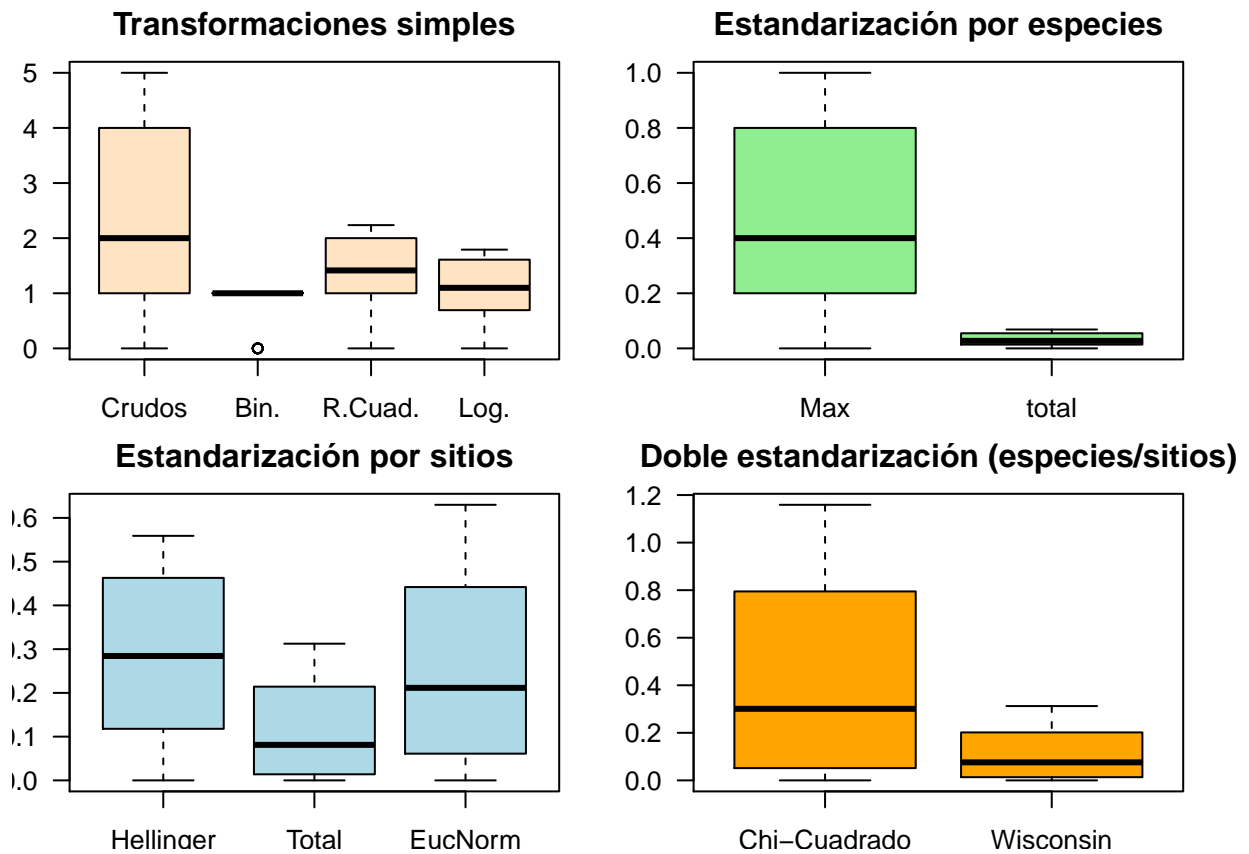
# Hacer la suma de los cuadrados igual a 1 (norma Euclidiana)
spe.norm <- decostand(spe,"normalize")
# verificación de la norma del vector fila (debe ser igual a 1)
norm <- function(x) sqrt(x%*%x)
# pista: apply(spe.norm,1,norm)

# Calcular las frecuencias relativas por filas (perfiles de los sitios)
# Luego le calculamos la raíz cuadrada
# A esto se llama la transformación de Hellinger
spe.hel <- decostand(spe,"hellinger")
# pista: apply(spe.hel,1,norm)

# Estandarización usando ambos, especies y sitios (perfiles dobles)
# *****
# Transformación Chi-cuadrado
spe.chi <- decostand(spe,"chi.square")
# Estandarización de Wisconsin:
# Primero se determina el rango de Las abundancias por la máxima de las especies y
# luego por el total de sitios
spe.wis <- wisconsin(spe)

# Inspeccionemos gráficamente las transformaciones
# *****
par(mfrow=c(2,2),mai=c(0.3,0.3,0.4,0.4))
boxplot(spe$LOC,spe.pa$LOC,spe.sqrt$LOC,spe.log1p$LOC,las=1,
        main="Transformaciones simples",
        names=c("Crudos","Bin. ","R.Cuad. ","Log."),col="bisque")
boxplot(spe.scal$LOC,spe.relsp$LOC,las=1,
        main="Estandarización por especies",
        names=c("Max","total"),col="lightgreen")
boxplot(spe.hel$LOC,spe.rel$LOC,spe.norm$LOC,las=1,
        main="Estandarización por sitios",
        names=c("Hellinger","Total","EucNorm"),col="lightblue")
boxplot(spe.chi$LOC,spe.wis$LOC,las=1,
        main="Doble estandarización (especies/sitios)",
        names=c("Chi-Cuadrado","Wisconsin"),col="orange")

```



**Fig. 8** Diagramas de caja de las transformaciones comunes echas a las abundancias de las especies. Como ejemplo, los datos ploteados pertenecen al espécimen **LOC** que hace referencia a la especie *Nemacheilus barbatulus* (Stone Loach)

También podemos observar estas transformaciones a lo largo del río:

```
# Inspeccionemos gráficamente las transformaciones a lo largo del río
# *****
par(mfrow=c(2,2),mai=c(0.7,0.7,0.4,0.4))
plot(env$das,spe$TRU,type="l",col=4,main="Datos crudos",
      xlab="Distancia de la fuente (km)",ylab="Ab. crudas")
lines(env$das,spe$OMB,col=3)
lines(env$das,spe$BAR,col="orange")
lines(env$das,spe$BCO,col=2)
lines(env$das,spe$LOC,col=1,lty="dotted")

plot(env$das,spe.scal$TRU,type="l",col=4,main="Perfil por especies",
      xlab="Distancia de la fuente (km)",ylab="Ab.Es. (Max)")
lines(env$das,spe.scal$OMB,col=3)
lines(env$das,spe.scal$BAR,col="orange")
lines(env$das,spe.scal$BCO,col=2)
lines(env$das,spe.scal$LOC,col=1,lty="dotted")

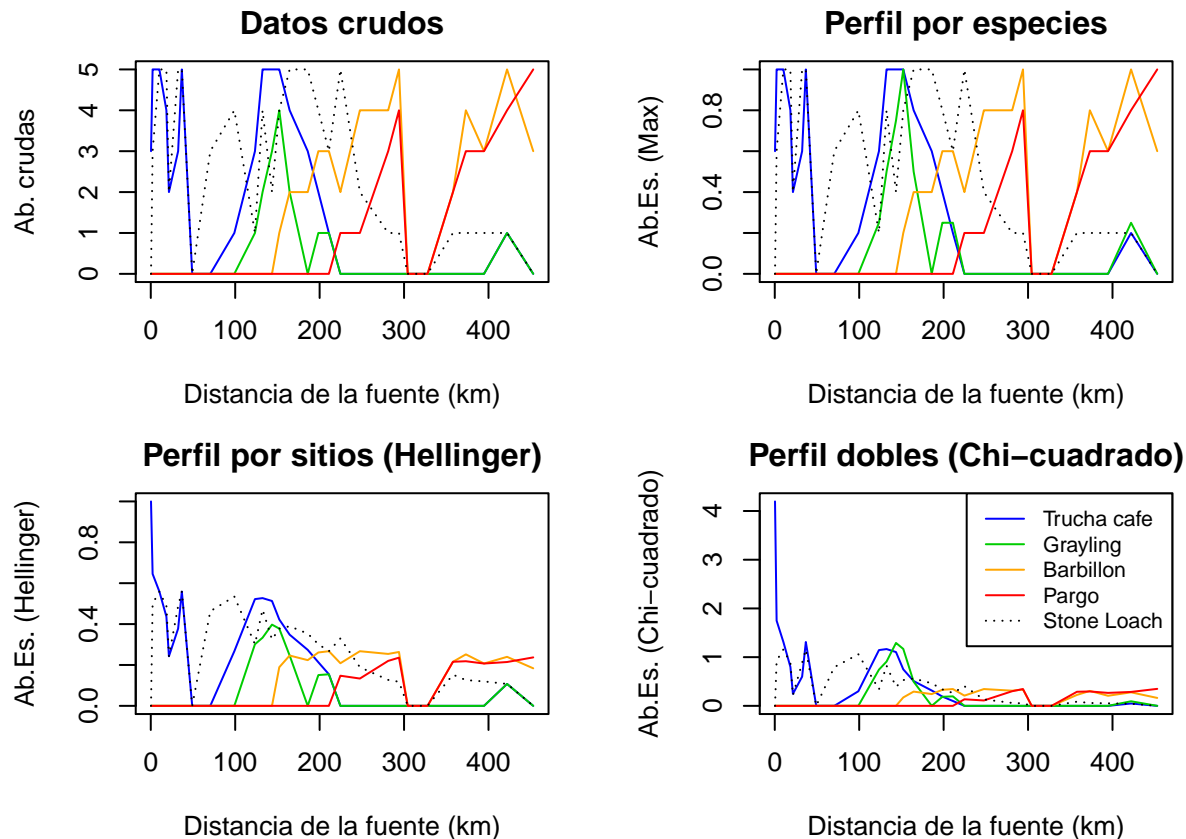
plot(env$das,spe.hel$TRU,type="l",col=4,main="Perfil por sitios (Hellinger)",
      xlab="Distancia de la fuente (km)",ylab="Ab.Es. (Hellinger)")
lines(env$das,spe.hel$OMB,col=3)
lines(env$das,spe.hel$BAR,col="orange")
lines(env$das,spe.hel$BCO,col=2)
```

```

lines(env$das,spe.hel$LOC,col=1,lty="dotted")

plot(env$das,spe.chi$TRU,type="l",col=4,main="Perfil doubles (Chi-cuadrado)",
      xlab="Distancia de la fuente (km)",ylab="Ab.Es. (Chi-cuadrado)")
lines(env$das,spe.chi$OMB,col=3)
lines(env$das,spe.chi$BAR,col="orange")
lines(env$das,spe.chi$BCO,col=2)
lines(env$das,spe.chi$LOC,col=1,lty="dotted")
legend("topright",c("Trucha cafe","Grayling","Barbillon","Pargo","Stone Loach"),
      col=c(4,3,"orange",2,1),lty=c(rep(1,4),3),cex=0.8)

```



**Fig. 9** Diagramas de las transformaciones a lo largo del río usando 5 especies de peces

**Qué similitudes y/o diferencias observamos en estos perfiles?**

### Datos ambientales

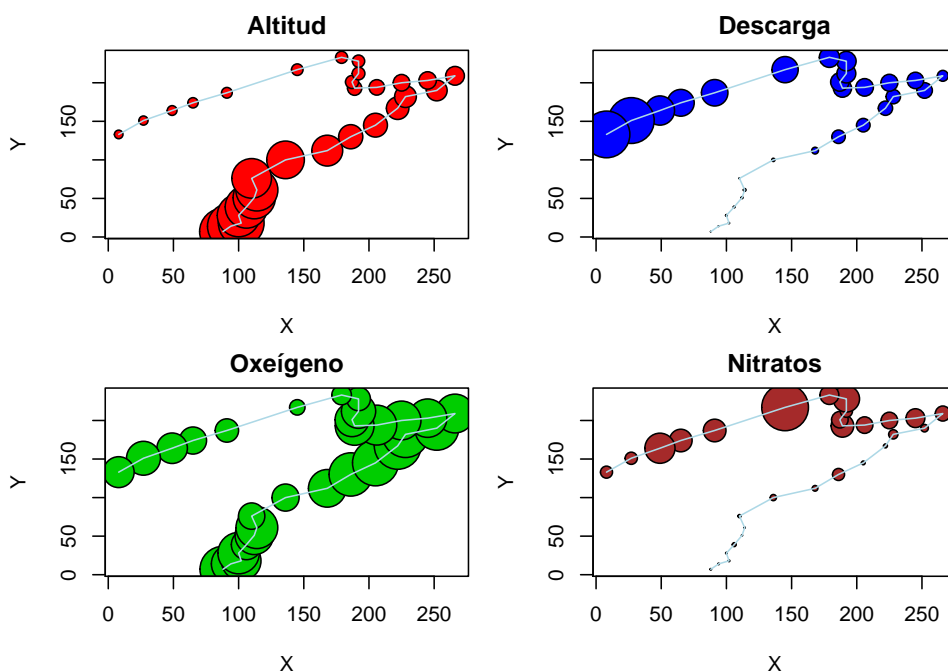
Una vez hemos explorado los datos de abundancia de especies, es tiempo de explorar los datos medioambientales colectados de los sitios de muestreo. Todos éstos datos estan almacenados en el objeto **env** que creamos al principio al importar el archivo que contenia dicha información. Lo primero que podemos hacer es usar la función **summary()** (pista: *summary(env)*) para explorar los datos y notar que tan diferentes son con respecto a los datos de abundancia de las especies.

A continuación, vamos a dibujar sobre el mapa del río algunas de las variables medioambientales primero como mapas de burbujas (**Fig. 10**) y luego en plots individuales siguiendo su cambio a lo largo del flujo del río (**Fig. 11**). Dado que el objeto **env** presenta las variables de acuerdo al codigo dado por Verneauux, en la **Tabla 1** pueden ver su decodificación y unidades utilizadas para la medición.

**Tabla 1** Variables medioambientales de los datos del rio Doubs.

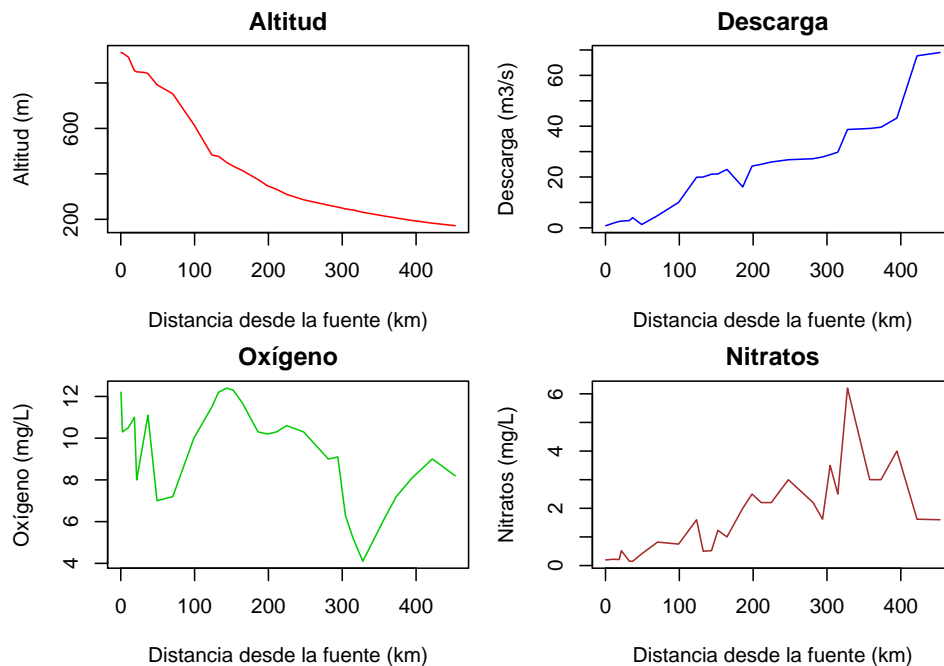
Variable	Codigo	Unidades
Distancia de la fuente	das	km
Altitud	alt	msnm
Pendiente	pen	grad
Media mínima de descarga	deb	m3/s
pH del agua	pH	-
Concentración de Ca (dureza)	dur	mg/L
Concentración de P	pho	mg/L
Concentración de nitratos (NO3)	nit	mg/L
Concentración de armonio (NH4)	amm	mg/L
Oxígeno disuelto	oxy	mg/L
Demanda de oxígeno biológico	duo	mg/L

```
# Mapa de burbujas de las variables medioambientales
# *****
par(mfrow=c(2,2),mai=c(0.7,0.7,0.4,0.4),mar=c(4,4,2,1))
plot(spa,main="Altitud",pch=21,col="black",bg="red",cex=5*env$alt/max(env$alt),
     xlab="X",ylab="Y")
lines(spa,col="light blue")
plot(spa,main="Descarga",pch=21,col="black",bg="blue",cex=5*env$deb/max(env$deb),
     xlab="X",ylab="Y")
lines(spa,col="light blue")
plot(spa,main="Oxígeno",pch=21,col="black",bg="green3",cex=5*env$oxy/max(env$oxy),
     xlab="X",ylab="Y")
lines(spa,col="light blue")
plot(spa,main="Nitratos",pch=21,col="black",bg="brown",cex=5*env$nit/max(env$nit),
     xlab="X",ylab="Y")
lines(spa,col="light blue")
```



**Fig. 10** Mapa de burbujas de cuatro variables medioambientales

```
# Plot de lienas
# *****
par(mfrow=c(2,2),mai=c(0.7,0.7,0.4,0.4),mar=c(4,4,2,1))
plot(env$das,env$alt,type="l",xlab="Distancia desde la fuente (km)",ylab="Altitud (m)",
     col="red",main="Altitud")
plot(env$das,env$deb,type="l",xlab="Distancia desde la fuente (km)",ylab="Descarga (m3/s)",
     col="blue",main="Descarga")
plot(env$das,env$oxy,type="l",xlab="Distancia desde la fuente (km)",ylab="Oxígeno (mg/L)",
     col="green3",main="Oxígeno")
plot(env$das,env$nit,type="l",xlab="Distancia desde la fuente (km)",ylab="Nitratos (mg/L)",
     col="brown",main="Nitratos")
```



**Fig. 11** Plot (línea) de cuatro variables medioambientales

También podemos explorar las relaciones pareadas entre las variables medioambientales. Para esto la función de R **pairs()** en un contexto gráfico es muy poderosa. Esta función dibuja una matriz de “scatter plots” en los que se grafican comparaciones pareadas entre variables (**Fig. 12**). Adicionalmente podemos adicionar una línea de tendencia (LOWESS) y un histograma de cada variable en la diagonal de la matriz, la cual muestre la distribución de frecuencia de los valores que toma cada una de las variables. Para generar este gráfico usaremos un script de Francois Gillet.

```
# Scatter plot de todas las comparaciones pareadas de las variables ambientales
# *****
# Cargar funciones adicionales a partir del script de Francois Gillet
source("./panelutils.R")
par(mfrow=c(1,1),pty="m")
pairs(env,panel=panel.smooth,diag.panel=panel.hist,
      main="Plots pareados con histogramas y líneas de tendencia")
```




## Plots pareados con histogramas y líneas de tendencia



**Fig. 12** Scatter plots entre los pares de las variables medioambientales con líneas de tendencia (LOWESS) e histogramas

Podemos usar transformaciones simples, tales transformación logarítmica para mejorar la distribución de algunas variables y acercarnos más a una distribución Normal. Adicionalmente, dado que estas variables son de dimensiones heterogéneas, es decir que se expresan en diferentes unidades y escalas, los análisis estadísticos futuros requieran que ellas sean estandarizadas a una media 0 y varianza 1 (Normalidad). Estas variables centradas y escaladas se llamarán “z-scores”. Miremos como se pueden llevar a cabo dichas transformaciones y estandarizaciones con un ejemplo (**Fig.13**).

```
# Transformaciones simples a las variables medioambientales
# *****
# Transformacion Log. de la variable "pendiente" (y=ln(x))
par(mfrow=c(2,2),mai=c(0.7,0.7,0.4,0.4))
hist(env$pen,col="bisque",right=FALSE,main="Histograma de env$pen")
hist(log(env$pen),col="light green",right=FALSE,main="Histograma de ln(env$pen)")
boxplot(env$pen,col="bisque",main="Boxplot de env$pen",ylab="env$pen")
boxplot(log(env$pen),col="bisque",main="Boxplot de ln(env$pen)",ylab="ln(env$pen)")
```



**Fig. 13** Histogramas y boxplots de datos no transformados (*izq.*) y datos log-transformados (*derecha*) para la variable **pen** (pendiente)

```
# Estandarización de todas las variables medioambientales
# *****
env.z <- decostand(env,"standardize")
head(apply(env.z,2,mean),n=5)
```

```
##          das          alt          pen          deb          pH
## 1.000429e-16 1.814232e-18 -1.659010e-17 1.233099e-17 -4.096709e-15
```

```
apply(env.z,2,sd)
```

```
## das alt pen deb pH dur pho nit amm oxy dbo
## 1 1 1 1 1 1 1 1 1 1 1
```

Responder: **Cómo son las distribuciones de los datos estandarizados vs. los datos crudos?**

## Asociaciones y sus medidas

Uno de los propósitos del estudio ecológico es comparar ciertas características, ya sean entre especies o entre sitios. Para generalizar vamos a definir 2 tipos de comparaciones: *modo Q* o *R*. Cuando un par de objetos (~sitios) es comparado, se dice que el análisis es de *modo Q*. Sin embargo, cuando las comparaciones son echas sobre un par de descriptores (~especies) entonces se dice que es un análisis *modo R*. Esta distinción es importante hacerla ya que las medidas de asociación para *modo Q* y *R* no son las mismas.

En *modo Q*, las medidas de asociaciones entre un par de objetos son basadas en **distancias de disimilaridad (o similitud)** (ej. distancias Euclidianas, Jaccard, Bray-Curtis, mahalanobis, etc.). En *modo R*, se usan medidas de **dependencia** entre variables, tales como covarianza o coeficiente de correlación (ej. Pearson, etc.).

## Modo Q: Calculo de matrices de distancia entre objetos (~sitios)

Para este modulo vamos a utilizar cuatro paquetes de R: **stats** (esta incluido cuando se instala R), **vegan**, **ade4**, **cluster** y **FD**.

### Nota informativa:

En R todas las medidas de similitud son convertidas a distancias para computar una matriz cuadrada de clase “dist”, en la que la diagonal (distancia entre un objeto y el mismo) es 0. De esta manera la diagonal puede ser ignorada. La conversión entre matrices de similitud y disimilaridad varia de acuerdo al paquete usado:

- En **stats**, **FD** y **vegan** la conversión de similitud  $S$  a disimilaridades  $D$  es:  $D = 1 - S$
- En **ade4**,  $D = \sqrt{1 - S}$

Para seguir explorando nuestros datos, vamos a calcular las disimilaridades entre nuestros sitios usando tres diferentes medidas :

1. Disimilaridad de *Bray-Curtis* (conocida tambien como la reciproca del indice de similitud de Steinhaus). Vamos a calcular esta matriz para los datos crudos y los datos de abundancia log-transformados.
2. La distancia “*chord*” es una distancia Euclidiana calculada a partir de los vectores de los sitios normalizados a longitud 1. Esta normalización es llamada “*chord*” y se hará utilizando la función **decostand()** del paquete **vegan** con el argumento *normalize*.
3. La distancia Hellinger, la cual es una distancia Euclidiana sobre los vectores de los sitios, donde los valores de abundancia son primero divididos por el total de la abundancia del sitio y al resultado se le saca la raíz cuadrada. A éste proceso se le llama transformación de Hellinger y se obtendrá usando la función **decostand()** con el argumento “hellinger”.

Para graficar las matrices vamos a usar el paquete de R gclus y el script “*codiss.R*” escrito por Francois Gillet, necesario para darle color de los heatmaps.

```
# Cargando los paquetes
library(ade4)
library(vegan)
library(gclus)
library(cluster)
library(FD)
source("./coldiss.R")
# Excluir el sitio de muestreo 8 el cual esta vacio (no peces)
spe <- spe[-8,];env <- env[-8,];spa <- spa[-8,]


# Calcular distancias y matrices de disimilaridad
# *****
```

```
# Bray-Curtis sobre datos crudos
spe.db <- vegdist(spe,"bray")
# Bray-Curtis sobre datos log-transformados
spe.dbln <- vegdist(log1p(spe),"bray")
# Distancia Chord
spe.norm <- decostand(spe,"norm")
spe.dc <- dist(spe.norm)
# Distancia Hellinger]
spe.hel <- decostand(spe,"hel")
spe.dh <- dist(spe.hel)
```


El color de los plots representa que tan similares o disimiles son los sitios comparados, asi que: **Magenta** = similaridad máxima (disimilitud cerca a 0) **Cyan** = similaridad mínima (disimilaridad cerca a 1)

```
# Graphicar las matrices de distancia
# *****
coldiss(spe.db,byrank=FALSE,diag=TRUE)
```

**Dissimilarity Matrix**




**Ordered Dissimilarity Matrix**




**Fig. 14** Heatmaps de la matriz de disimilaridad de Bray-Curtis calculada con base en los datos crudos

```
coldiss(spe.dh,byrank=FALSE,diag=TRUE)
```

**Dissimilarity Matrix**




**Ordered Dissimilarity Matrix**



**Fig. 15** Heatmaps de la matriz de distancia **Hellinger** calculada con base en los datos hellinger-transformados

```
# Matriz de disimilaridad de Jaccard (datos binarios)
spe.dj <- vegdist(spe,"jac",binary=TRUE)
coldiss(spe.dj,byrank=FALSE,diag=TRUE)
```

## Dissimilarity Matrix



## Ordered Dissimilarity Matrix




Fig. 16 Heatmaps de la matriz de distancia de **Jaccard** calculada con base en los datos hellinger-transformados


Hacer los otros heatmaps para Braz-Curtis con datos log-transformados, y demas transformaciones. Ahora comparar las distancias o matrices de disimilaridad, incluyendo la de matriz con datos transformados en binarios y discutir que tan similares son

## Modo Q para analizar los datos cuantitativos medioambientales


Dado que los datos medioambientales tienen una escala diferente, es decir fueron medidos de manera diferente y por tanto unidades diferentes; los datos deberan estandarizarse a (z-scores). Dicha estandarización ayudará a disminuir los sesgos al calcular la distancia Euclidiana. Por lo tanto, para comparar los sitios con base en los datos medioambientales vamos a calcular la matriz de distancias Euclidiana sobre los datos medioambientales estandarizados (z-scores). Adicionalmente vamos a remover la variable "das" (distancia desde la fuente), ya que es una medida de posición espacial y no un descriptor o variable medioambiental.

```
# Remover variable "das" del objeto env
env2 <- env[,-1]
# Matriz de disimilaridad sobre datos (env2) estandarizados
env.de <- dist(decostand(env2,"standardize"))
coldiss(env.de,byrank=FALSE,diag=TRUE)
```

## Dissimilarity Matrix



## Ordered Dissimilarity Matrix



## *Modo R* para calcular la dependencia de matrices entre variables

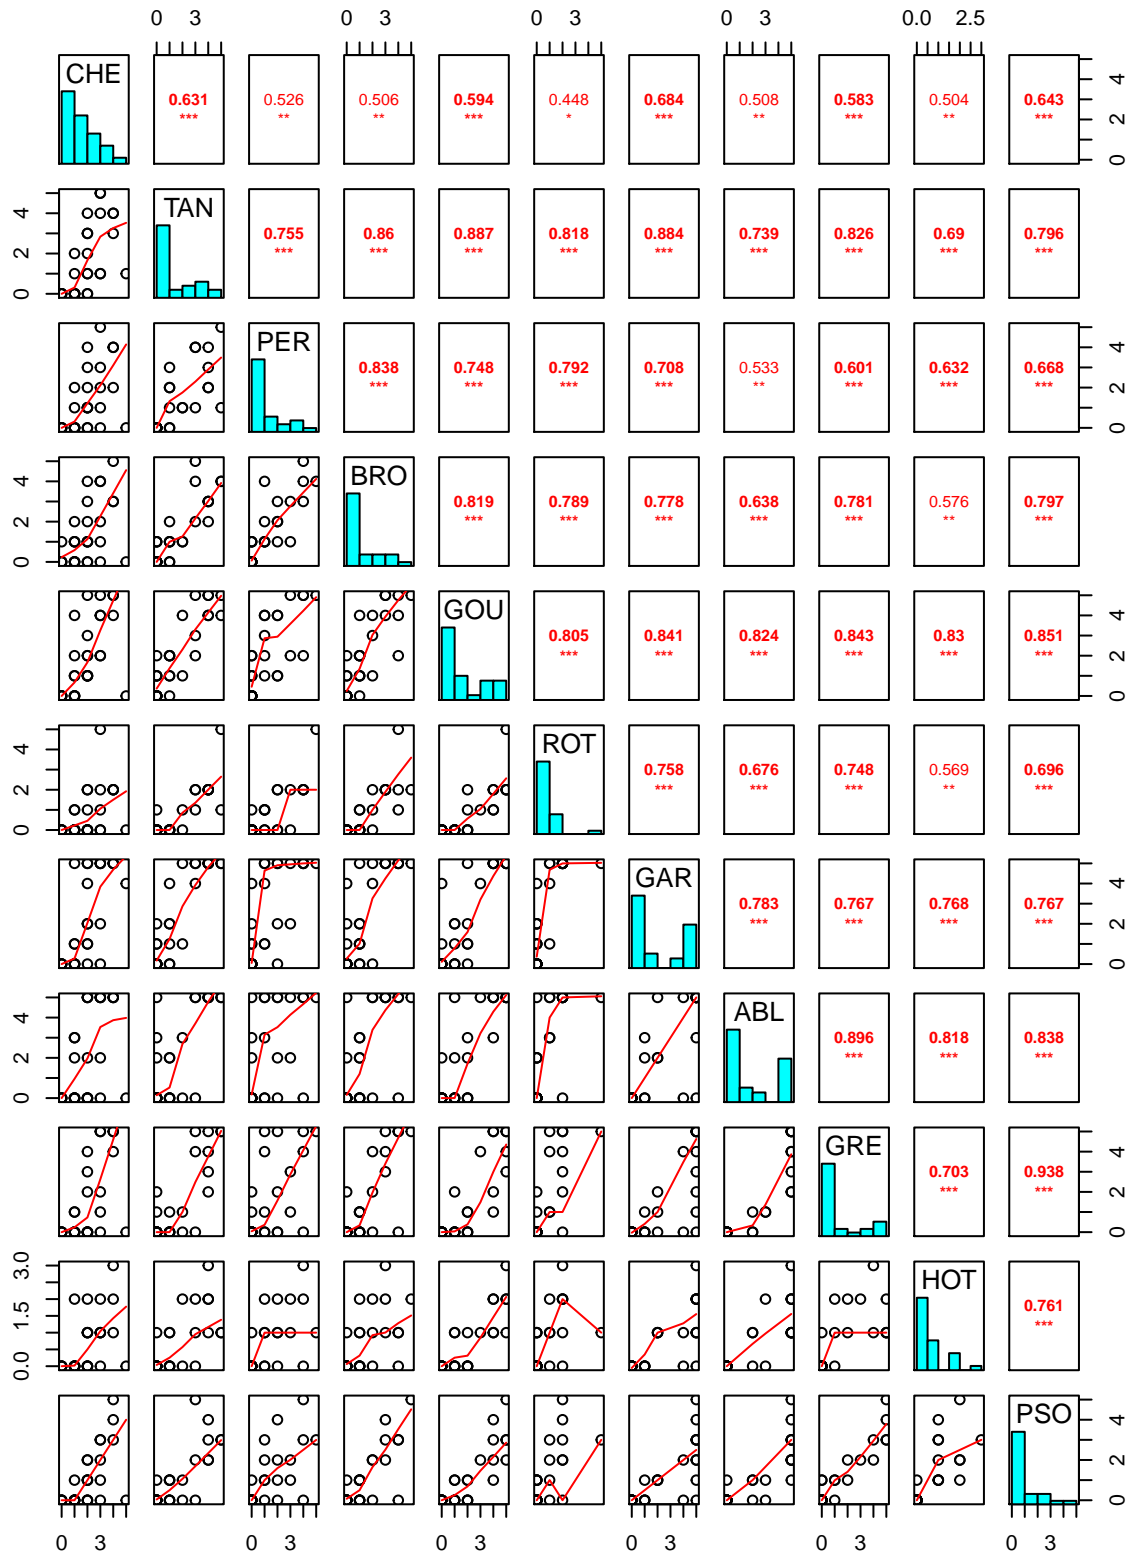
Coefficientes de correlación son usados para comparar variables cuantitativas o semi-cuantitativas en el *Modo R*. Entre estos coeficientes se incluyen el de Pearson para datos paramétricos (con distribución Normal) o Spearman or Kendall como coeficientes de correlación para datos no paramétricos. Para datos cualitativos normalmente se usan estadísticos de contingencia tales como el Chi-cuadrado y sus formas derivados. Para datos binarios (presencia-ausencia) se usan coeficientes como el de Jaccard, Sørensen y Ochiai, los cuales sirven para comparar entre especies.

## *Modo R* usado para comparar la abundancia entre especies

En el caso particular de abundancias, es normal usar covarianzas para comparar entre distribuciones de especies en función del espacio o tiempo, y a demás se pueden aplicar tanto para datos paramétricos como no paramétricos. Sin embargo, este tipo de datos de abundancia esta caracterizado por contener una gran cantidad de ceros. Al comparar distribuciones los ceros contribuyen a incrementar los indices de correlacion. Por lo tanto datos de abundancia de especies debe tratarse (transformarse) previo al análisis. Legendre y Gallagher (2001) propusieron 5 posibles transformaciones de los datos y cuatro de ellas se encuentran en la función `decostand()` del paquete `vegan` ("total", "normalize", "hellinger", "chi.square"). Todas estos métodos expresan los datos como abundancias relativas por sitio (perfiles de sitio) removiendo la abundancia total del sitio. En la transformación de Hellinger, a las abundancias relativas se les calcula la raíz cuadrada, lo cual reduce fuertemente la influencia de datos con alta abundancia.

```
# Transformar datos de abundancia usando Hellinger
spe.hel <- decostand(spe,"hellinger")
# Matriz de disimilaridad sobre datos (env2) estandarizados
spe.hpear <- round(cor(spe.hel),2)
# Ordenar las variables de acuerdo para plotearlas
spe.o <- order.single(spe.hpear)
source("./panelutils.R")
pairs(spe[,spe.o[1:11]],lower.panel=panel.smooth,upper.panel=panel.cor,
      diag.panel=panel.hist,cex.cor=0.8,
      main="Correlaciones de Pearson - especies")
```

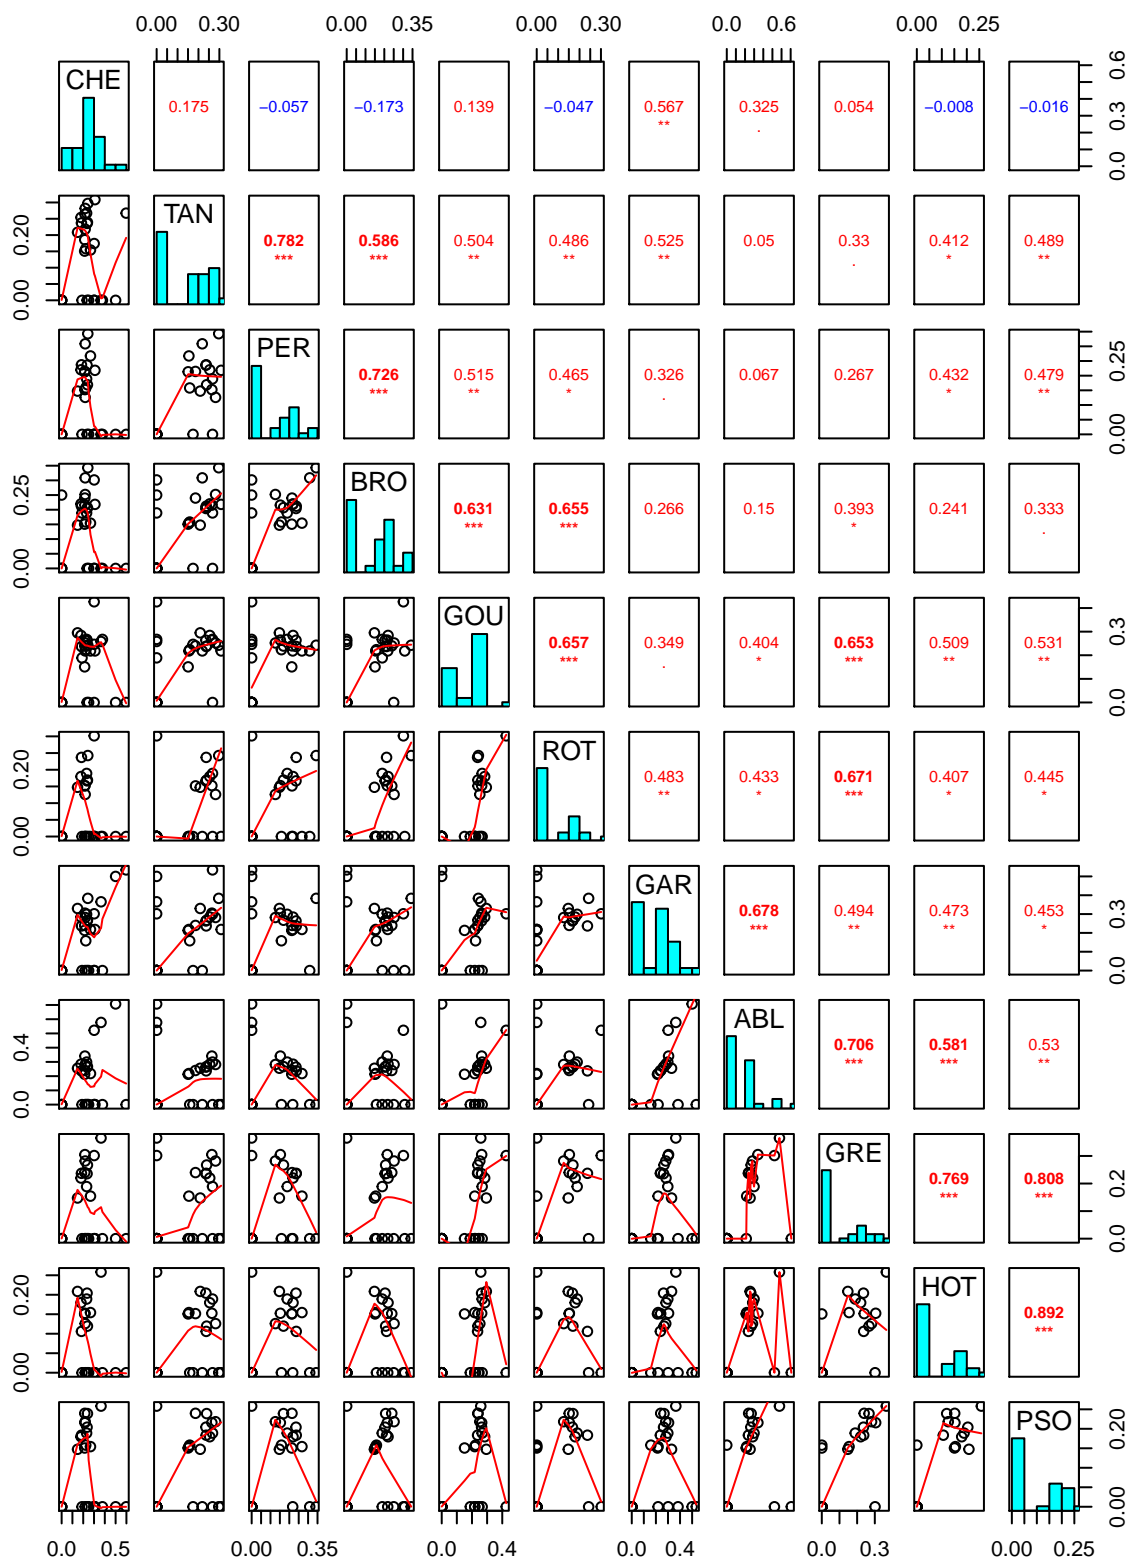
## Correlaciones de Pearson – especies



```
pairs(spe.hel[,spe.o[1:11]],lower.panel=panel.smooth,upper.panel=panel.cor,
      diag.panel=panel.hist,cex.cor=0.8,
```

```
main="Correlaciones de Pearson - especies")
```

## Correlaciones de Pearson – especies





## Analisis de cluster

La clusterización de los datos tiene por objetivo identificar grupos de objetos similares en un espacio de datos multivariado. Similaridades entre observaciones (o individuos) es definida usando algunas medidas de distancia entre observaciones tales como distancias Euclidianas o medidas de distancia basadas en correlación.

Hay diferentes técnicas de clusterización de las cuales podemos destacar:

- *Clusterización por partición*, en esta aproximación se subdividen a priori los datos en  $k$  grupos. Uno de los métodos más usados es el *k-means*.
- *Clusterización jerárquica*, esta aproximación identifica grupos sin subdividir los datos.

## Métodos para medir distancias

La escogencia de la medida de distancia es muy importante dado que esta influye en el resultado de la clusterización. La distancia más usada es la distancia Euclídeana. Sin embargo, depende del tipo de datos y de la pregunta de investigación alguna otra medida puede ser preferida. Por ejemplo, en análisis de expresión génica (Modo R) es normalmente usada una distancia basada en correlaciones (Pearson).

Distancias basadas en correlaciones consideran 2 objetos similares si sus características son altamente correlacionadas, incluso si sus valores son tan diferentes que usando distancias Euclidianas sugieren ausencia de similaridad. Así, cuando la distancia entre 2 objetos es igual a 0, lo interpretamos como objetos perfectamente correlacionados. Cabe notar que la correlación de Pearson es sensible a datos extremos, no obstante, para mitigar dicho efecto es posible usar correlación de Spearman en su lugar.

Las medidas de distancia están intimamente relacionadas a la escala (unidades) de las variables medidas. Por lo tanto, es altamente recomendable escalar (estandarizar) las variables antes de calcular las distancias. La función `scale()` de R transforma los datos de la siguiente manera:

$$\frac{x_i - \mu}{\sigma}$$


## Clusterización por particiones

*K-means* y *PAM* (partición alrededor de medoides) es una técnica de clusterización que requiere una subdivisión los datos en un conjunto de  $k$  grupos, donde  $k$  es un numero especificado por el investigador. *K-means* es un método más susceptible a valores extremos en comparación a *PAM*. Sin embargo, es posible determinar cual podría ser el número optimo de cluster de la siguiente manera.

```
library(factoextra)
library(cluster)
library(pheatmap)


spe.hel <- decostand(spe,"normalize")
# K means
fviz_nbclust(spe.hel,kmeans,method="gap_stat")
```

Optimal number of clusters




```
spe.km <- kmeans(spe.hel,4,nstart=25)
fviz_cluster(spe.km,data=spe.hel,palette="jco")
```


Cluster plot



```
# PAM
fviz_nbclust(spe.hel,pam,method="silhouette")
```



```
spe.pam <- pam(spe.hel,k=2,metric="euclidean")
fviz_cluster(spe.pam,data=spe.hel,palette="jco")
```




## Clusterización por “*Clustering jerárquico*”

Ésta técnica de clusterización no requiere una subdivisión los datas en un conjunto de  $k$  grupos. El resultado de esta técnica produce una representación de los datas basado en un “*árbol*” conocido como **dendograma**. Las observaciones pueden subdividirse en grupos cortando el dendograma a un nivel de similaridad específico.


```
library(factoextra)
library(cluster)
library(pheatmap)

spe.hel <- decostand(spe,"normalize")
spe.dis <- dist(spe.hel)
spe.hc <- hclust(spe.dis,method="ward.D2")
fviz_dend(spe.hc,cex=0.5,k=4,palette="jco")
```

Cluster Dendrogram

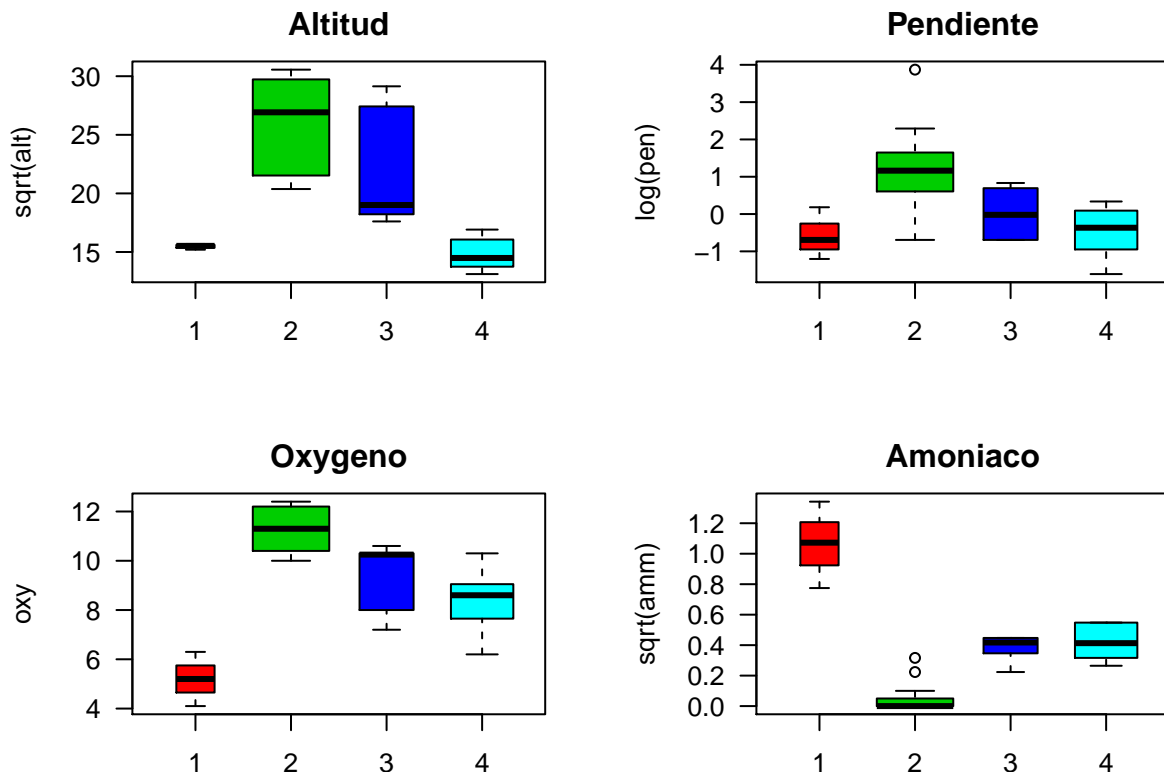


```
heatmap(t(spe.hel),cutree_cols=4)
```



```
# Relaciones entre clusters de peces y 4 variables medioambientales
# *****
```

```
par(mfrow=c(2,2),mai=c(0.7,0.7,0.4,0.4))
boxplot(sqrt(env$alt)~spe.km$cluster,main="Altitud",las=1,
        ylab="sqrt(alt)",col=2:5,varwidth=TRUE)
boxplot(log(env$pen)~spe.km$cluster,main="Pendiente",las=1,
        ylab="log(pen)",col=2:5,varwidth=TRUE)
boxplot(env$oxy~spe.km$cluster,main="Oxígeno",las=1,
        ylab="oxy",col=2:5,varwidth=TRUE)
boxplot(sqrt(env$amm)~spe.km$cluster,main="Amoníaco",las=1,
        ylab="sqrt(amm)",col=2:5,varwidth=TRUE)
```



## Metodos Ordinales sin constricciones

Mientras el análisis de clusters busca por discontinuidades entre el set de datos, los métodos ordinales extraen las principales tendencias en la forma de ejes continuos. De esta manera estos métodos se adaptan muy bien al análisis de datos estructurados sobre gradientes.

### \*\* Espacio multidimensional\*\*

Los datos multivariados pueden ser vistos como una colección de sitios posicionados en un espacio donde cada variable define una dimensión. Por lo tanto, uno puede imaginar que hay tantas dimensiones como variables. Entonces, para revelar la estructura de los datos sería interesante representar las tendencias principales en forma de “scatterplots” de los sitios. Dado que los datos ecológicos generalmente contienen más de dos variables, no es informativo, impráctico y si muy tedioso graficar cada objeto en una serie de planos definidos por cada uno de los descriptores. Por ejemplo, si los descriptores son 10, el número de planos a dibujar sería igual a  $(10 \times 9) / 2 = 45$   $((n(n-1))/2)$ . El objetivo de los métodos ordinales es la representación gráfica de

los datos sobre un número reducido de ejes ortogonales, contruidos de tal manera que su representación represente la variabilidad de los datos.

La mayoría de los métodos ordinales (excepto NMDS) se basan en la extracción de los vectores propios de una matriz de asociación. Ellos pueden ser clasificados de acuerdo a la distancia calculada entre los sitios y el tipo de variables evaluada.

- *Análisis de componentes Principales (PCA)*: El método está basado principalmente en el cálculo de vectores propios. Trabaja sobre datos crudos y datos cuantitativos. Usa distancias euclidianas entre los sitios.
- *Análisis de correspondencias (CA)*: El método trabaja sobre datos que deben ser frecuencias con dimensionalidad homogénea y no negativas. Usa una medida de distancia Chi-cuadrado entre las filas o columnas. Es usualmente usado en ecología para analizar tablas de datos de especies.
- *Análisis de coordenadas Principales (Principal Coordinate - PCoA)*: El método usa matrices de distancia para calcular los componentes ordinales. Esta aproximación es usada en análisis *modo Q*, en vez de tablas sitio - variable. Por lo tanto proporciona gran flexibilidad en la elección de las medidas de asociación.
- *Escalamiento no numérico multidimensional (NMDS)*: A diferencia de los otros tres métodos, este no usa un cálculo de vectores propios. NMDS trata de representar el conjunto de objetos a lo largo de un número predeterminado de ejes preservando la relación de orden entre ellos.

PCoA y NMDS pueden producir resultados ordinales desde cualquier matriz de distancia cuadrada.

```
library(ade4)
library(factoextra)
library(vegan)
library(pheatmap)

# Importando datos (por si acaso)
# *****
spe <- read.csv('../data/DoubsSpe.csv', row.names=1)
env <- read.csv('../data/DoubsEnv.csv', row.names=1)
spa <- read.csv('../data/DoubsSpa.csv', row.names=1)
# Remover el sitio vacío
spe <- spe[-8,]
env <- env[-8,]
spa <- spa[-8,]
# PCA
env.pca <- rda(env, scale=TRUE) # usando datos estandarizados
env.pca
```

```
## Call: rda(X = env, scale = TRUE)
##
##              Inertia Rank
## Total              11
## Unconstrained      11   11
## Inertia is correlations
##
## Eigenvalues for unconstrained axes:
##  PC1  PC2  PC3  PC4  PC5  PC6  PC7  PC8  PC9  PC10  PC11
## 6.098 2.167 1.038 0.704 0.352 0.319 0.165 0.112 0.023 0.017 0.006
```



Para mayor información usar la función `summary()`

```
summary(env.pca)
```

Vocabulario:

- **Inercia**: en el lenguaje de **vegan**, éste término se refiere a “variación” en los datos. En PCA la inercia es ya sea la suma de varianzas de las variables (PCA sobre una matriz de covarianza) o en éste caso (PCA sobre una matriz de correlaciones), es la suma de los valores diagonales de la matriz de correlaciones.
- **“Constrained y unconstrained”**: Tiene que ver con ordenación canónica. El análisis PCA es “unconstrained”.
- **“Eigenvalues” (valores propios)**: Éstos son las medidas de la importancia (varianza medida) de los ejes. Ellos pueden entenderse como las proporciones de varianza o variabilidad explicadas de toda la inercia de los datos.
- **“Scaling”**: No tiene nada que ver con estandarización. En este caso se refiere a la manera en que los resultados son proyectados en el contexto gráfico y de visualización. 2 tipos principales de “scaling” son generalmente usados.
  - **PCA scaling 1**: biplot de distancia. (1) **Distancias entre objetos en el biplot son aproximaciones de sus distancias euclidianas.** (2) Los ángulos entre los vectores de los descriptores no tienen significado
  - **PCA scaling 2**: biplot de correlaciones (1) Distancias entre objetos en el biplot NO son aproximaciones de sus distancias euclidianas. (2) **Los ángulos entre los vectores de los descriptores reflejan sus correlaciones**
- **“Scores” de las especies**: Coordenadas de las cabezas de las flechas de las variables en el diagrama.
- **“Scores” de los sitios**: Coordenadas de los sitios en el diagrama.


```
# Graficar PCA
par(mfrow=c(1,2))
biplot(env.pca,scaling=1,main="PCA - scaling 1")
biplot(env.pca,scaling=2,main="PCA - scaling 2")
```



## Combinando clustering y resultados ordinales

Combinar analisis de clusters y resultados ordinales puede permitir explicar o confirmar diferencias entre grupos de sitios.

```
# Combinando clustering y resultados ordinales
# *****8*****
env.w <- hclust(dist(scale(env)), "ward.D")
# cortar el dendrograma para lograr 4 clusters
gr <- cutree(env.w, k=4)
grl <- levels(factor(gr))
# conseguir los scores (coordenadas) de sitios, scaling 1
sit.scl <- scores(env.pca, display="wa", scaling=1)
# Plotear los sitios con los símbolos de los clusters y colores
p <- plot(env.pca, display="wa", scaling=1, type="n",
          main="PCA correlacion + clusters")
abline(v=0, lty="dotted", col="grey")
abline(h=0, lty="dotted", col="grey")
for(i in 1:length(grl)){
  points(sit.scl[gr==i,], pch=(14+i), cex=2, col=i+1)
}
text(sit.scl, row.names(env), cex=0.6, pos=3)
# Añadir el dendrograma
ordicluster(p, env.w, col="dark grey")
legend("topright", paste0("Group ", c(1:length(grl))),
      pch=c(14+c(1:length(grl))),
      col=c(1+c(1:length(grl))), pt.cex=2)
```






## Análisis de Correspondencias (CA)

Este método es uno de los más usados para el análisis de datos de presencia-ausencia o abundancia de especies. En este método la diferencia entre sitios es medida a través de la distancia Chi-cuadrado ( $\chi^2$ ). La distancia  $\chi^2$  no es influenciada por los dobles ceros. Por lo tanto CA es un método adaptado para el análisis de abundancia de especies sin una pre-transformación. Tener siempre en cuenta que los datos usados en un CA deben ser frecuencias dimensionalmente homogéneas y no negativas. Como en PCA, CA puede ser representado en dos scalings:


- **CA scaling 1:** Es el más apropiado si uno está interesado en analizar los sitios. Se interpreta como (1) las distancias entre objetos (sitios) en el espacio reducido se aproxima a sus distancias  $\chi^2$ . Por lo tanto **los sitios que estan juntos a otros es probable que sean relativamente similares en sus perfiles de frecuencias relativas de especies**. (2) Cualquier objeto (sitio) que se encuentre cerca a un punto que represente alguna especie es probable que contenga una alta contribución de esa especie.
- **CA scaling 2:** Es el más apropiado si uno está interesado en analizar las especies. Se interpreta como (1) Distancias entre especies se aproxima a sus distancias  $\chi^2$ . De esta manera **las especies que estan cerca una de la otra es por que es más probable que sus frecuencias relativas a lo largo de los sitios evaluados sean similares**. (2) Cualquier especie que este cerca a un punto que represente un sitio es por que es altamente probable que esta especie sea encontrada en este sitio, o que tenga una mas alta abundancia ese sitio que en cualquier otro.

```
# Calcular CA
spe.ca <- cca(spe)
# Graficar CA
par(mfrow=c(1,2))
plot(spe.ca,scaling=1,main="CA abundancia de peces - scaling 1")
plot(spe.ca,scaling=2,main="CA abundancia de peces - scaling 2")
```

CA abundancia de peces – scaling 1



CA abundancia de peces – scaling 2



Combinando clustering y resultados ordinales:


```
# Combinando clustering y resultados ordinales
# *****8*****
env.w <- hclust(dist(scale(env)), "ward.D")
# cortar el dendrograma para lograr 4 clusters
gr <- cutree(env.w, k=4)
gr1 <- levels(factor(gr))
```

```

# conseguir los scores (coordenadas) de sitios, scaling 1
sit.scl <- scores(spe.ca,display="wa",scaling=1)
spe.scl <- scores(spe.ca,display="species",scaling=1)
# Plotear los sitios con los símbolos de los clusters y colores
p <- plot(spe.ca,display="wa",scaling=1,type="n",
          main="CA correlacion + clusters")
abline(v=0,lty="dotted",col="grey")
abline(h=0,lty="dotted",col="grey")
for(i in 1:length(grl)){
  points(sit.scl[gr==i,],pch=(14+i),cex=2,col=i+1)
}
text(spe.scl,row.names(spe.scl),col="black",pos=2)
text(sit.scl,row.names(env),cex=0.8,pos=3)
# Añadir el dendrograma
ordicluster(p,env.w,col="dark grey")
legend("topright",paste0("Group ",c(1:length(grl))),
      pch=c(14+c(1:length(grl))),
      col=c(1+c(1:length(grl))),pt.cex=2)

```

CA correlacion + clusters




## Explicando las distribuciones usando las variables ambientales (*Post Hoc*)

Aunque hay otras formas de incorporar variables explicatorias directamente sobre el proceso de la análisis ordinal (Ordinación canónica), uno puede estar interesado en incluir variables externas en un método ordinal simple. Para esto **vegan** usa su función **envfit()**. De acuerdo al autor Jari Oksanen, “**envfit** encuentra los vectores o factores promedio de las variables ambientales. Las proyecta de los puntos sobre los vectores tienen

los valores máximos de correlación con las variables ambientales correspondientes”

```
# Ajustar medioambiente sobre el CA
spe.ca.env <- cca(spe~.,env)
# Graficar CA enfit
par(mfrow=c(1,2))
plot(spe.ca.env,scaling=1,main="CA-env abundancia de peces - scaling 1")
plot(spe.ca.env,scaling=2,main="CA-env abundancia de peces - scaling 2")
```

CA-env abundancia de peces – scaling 1



CA-env abundancia de peces – scaling 2

