

Introduction al modelamiento ecológico

Guillermo G. Torres PhD

Sobre este curso y sus datos

Los datos que utilizarán en este curso fueron usados en la tesis doctoral de Verneaux (Verneaux et al. 2003). Él propuso que se podían usar algunas especies de peces para caracterizar zonas ecológicas a lo largo de ríos y arroyos en Europa. Verneaux demostró que las comunidades de peces eran buenos indicadores biológicos para estos cuerpos de agua. En este curso vamos a tratar de llegar a la misma conclusión.

Los datos consisten en 3 matrices que contienen parte de los datos usados por Verneaux. Estos datos han sido colectados de 30 sitios a lo largo del río *Doubs*, el cual corre entre Francia y Suiza en las montañas Jura. La primera matriz (*spe*) de datos contiene las abundancias de 27 especies de peces, la segunda matriz (*env*) contiene 11 variables ambientales relacionadas con la hidrología, geomorfología y química del río. La tercera matriz (*spa*) contiene las coordenadas geográficas (Cartesianas, X y Y) de los sitios.

Análisis exploratorio de los datos

Los análisis exploratorios son métodos que usan herramientas de visualización y calcula descriptores sintéticos que son requeridos para ganar información referente a:

- Tener una visión global de los datos
- Transformar o recodificar algunas variables
- Orientar análisis futuros

Exploración de los datos *Doubs*

Al comienzo de cada sesión de trabajo se recomienda definir el directorio o carpeta de trabajo. Si se usa Rstudio, el directorio de trabajo se puede definir yendo a:

- Sesión
 - Definir directorio de trabajo
 - Escojer directorio

En la consola de se puede definir de la siguiente manera:

```
setwd('/direccion/de/la/carpeta/de/trabajo/')
```

Una vez definido el directorio de trabajo vamos a cargar los datos.

```
# Importar los datos desde archivos de texto, ej. formato CSV
# *****
# Matriz de las especies de peces (data frame de las abundancias de los peces):
spe <- read.csv('../data/DoubsSpe.csv', row.names=1)
# Matriz de los datos ambientales:
env <- read.csv('../data/DoubsEnv.csv', row.names=1)
# Matriz de la informacion espacial (Coordenadas geograficas X,Y):
spa <- read.csv('../data/DoubsSpa.csv', row.names=1)
```

Echemos un vistazo a los datos de la comunidad (objeto **spe**, abundancia de los peces)

```
# funciones básicas
# *****
# Muestra el data frame completo (No recomendado para set de datos grandes):
spe
```

```

# Muestra solamente las primeras 5 líneas:
head(spe)

# Muestra la dimensión del dataframe (No. filas, No. columnas):
dim(spe)

## [1] 30 27

# Muestra el No. de filas:
nrow(spe)

## [1] 30

# Muestra el No. columnas:
ncol(spe)

## [1] 27

# Muestra solamente 5 filas y 10 columnas:
spe[1:5,1:10]

##   CHA TRU VAI LOC OMB BLA HOT TOX VAN CHE
## 1   0   3   0   0   0   0   0   0   0   0
## 2   0   5   4   3   0   0   0   0   0   0
## 3   0   5   5   5   0   0   0   0   0   0
## 4   0   4   5   5   0   0   0   0   0   1
## 5   0   2   3   2   0   0   0   0   5   2

# Nombre de las columnas (descriptores = especies):
colnames(spe)

## [1] "CHA" "TRU" "VAI" "LOC" "OMB" "BLA" "HOT" "TOX" "VAN" "CHE" "BAR"
## [12] "SPI" "GOU" "BRO" "PER" "BOU" "PSO" "ROT" "CAR" "TAN" "BCO" "PCH"
## [23] "GRE" "GAR" "BBO" "ABL" "ANG"

# Nombre de las filas
rownames(spe)

## [1] "1" "2" "3" "4" "5" "6" "7" "8" "9" "10" "11" "12" "13" "14"
## [15] "15" "16" "17" "18" "19" "20" "21" "22" "23" "24" "25" "26" "27" "28"
## [29] "29" "30"

# Estadísticos descriptivos para las columnas
summary(spe)

##           CHA           TRU           VAI           LOC
## Min.      :0.00   Min.      :0.00   Min.      :0.000   Min.      :0.000
## 1st Qu.:0.00   1st Qu.:0.00   1st Qu.:0.000   1st Qu.:1.000
## Median :0.00   Median :1.00   Median :3.000   Median :2.000
## Mean     :0.50   Mean     :1.90   Mean     :2.267   Mean     :2.433
## 3rd Qu.:0.75   3rd Qu.:3.75   3rd Qu.:4.000   3rd Qu.:4.000
## Max.     :3.00   Max.     :5.00   Max.     :5.000   Max.     :5.000

```

Usando la mediana y la media de las abundancias. Las distribuciones son simétricas?

```

# Distribución general de las abundancias
# *****
# Mínimo y máximo valor de las abundancias de todo el set de datos:
range(spe)

```

```
## [1] 0 5
# Número de especies ausentes
sum(spe==0)

## [1] 435
# Proporción de ceros en el set de datos
sum(spe==0)/(nrow(spe)*ncol(spe))

## [1] 0.537037
# Conteo de especies con 0,1,2,3 o n de abundancia (clases)
ab <- table(unlist(spe))
# Diagrama de barras de la distribución de abundancia de las especies
barplot(ab,las=1,xlab="Clases de abundancia",ylab="Frecuencia",co=gray(5:0/5))
```




Fig. 1 Diagrama de barras de las clases de abundancia

Mirando el diagrama de barras sobre las clases de abundancia, cómo se interpretaría la alta frecuencia de ceros (ausencias) en el set de datos?

Ahora usemos los datos geograficos para generar una representación gráfica de la ubicacion de los sitios de muestreo.

```
# Mapear la posición de los sitios
# *****
# 1. Creamos un lienzo en blanco donde estarán los puntos de muestreo
plot(spa,type='n',main="Localizacion de los sitios de muestreo",
     xlab="Coordenada X (km)",ylab="Coordenada Y (km)")
# 2. Adicionamos una línea que conecta los puntos de muestreo (simulemos el río)
lines(spa,col="light blue",lwd=11)
# 3. Adicionamos los puntos de muestreo
text(spa, rownames(spa),cex=0.8,col="red")
```

```
# 4. Adicionamos la direccion del rio
text(50,10,"Corriente arriba",cex=0.8,col="red")
text(30,120,"Corriente abajo",cex=0.8,col="red")
```

Localizacion de los sitios de muestreo




Fig. 2 Mapa de los 30 sitios de muestreo en el río *Doubs*

Ahora que le hemos dado vida al río ya podemos ubicar los peces y su distribución sobre él. Vamos a plotear algunas de las especies de peces que seleccionó Verneauux. El por qué de estas especies lo veremos más adelante en la guía y tal vez generemos nuevos y más interesantes plots :).

```
# Mapas de las abundancias de algunos de las especies de peces
# *****
# 1. Dividimos la ventana de graficos en 4 (para plotear 4 figuras a la vez)
par(mfrow=c(2,2),mai=c(0.7,0.7,0.4,0.4))
# 2. Ploteamos... (cex es usado para definir el tamaño de algún item en la gráfica)
# Trucha café
plot(spa,col="brown",cex=spe$TRU,main="Trucha café",
     xlab="Coordenada X (km)",ylab="Coordenada Y (km)")
lines(spa,col="light blue",lwd=1)
# Grayling
plot(spa,col="brown",cex=spe$OMB,main="Grayling",
     xlab="Coordenada X (km)",ylab="Coordenada Y (km)")
lines(spa,col="light blue",lwd=1)
# Barber
plot(spa,col="brown",cex=spe$BAR,main="Barbillon ",
     xlab="Coordenada X (km)",ylab="Coordenada Y (km)")
lines(spa,col="light blue",lwd=1)
# Pargo
plot(spa,col="brown",cex=spe$BCO,main="Pargo común",
     xlab="Coordenada X (km)",ylab="Coordenada Y (km)")
```

```
lines(spa,col="light blue",lwd=1)
```

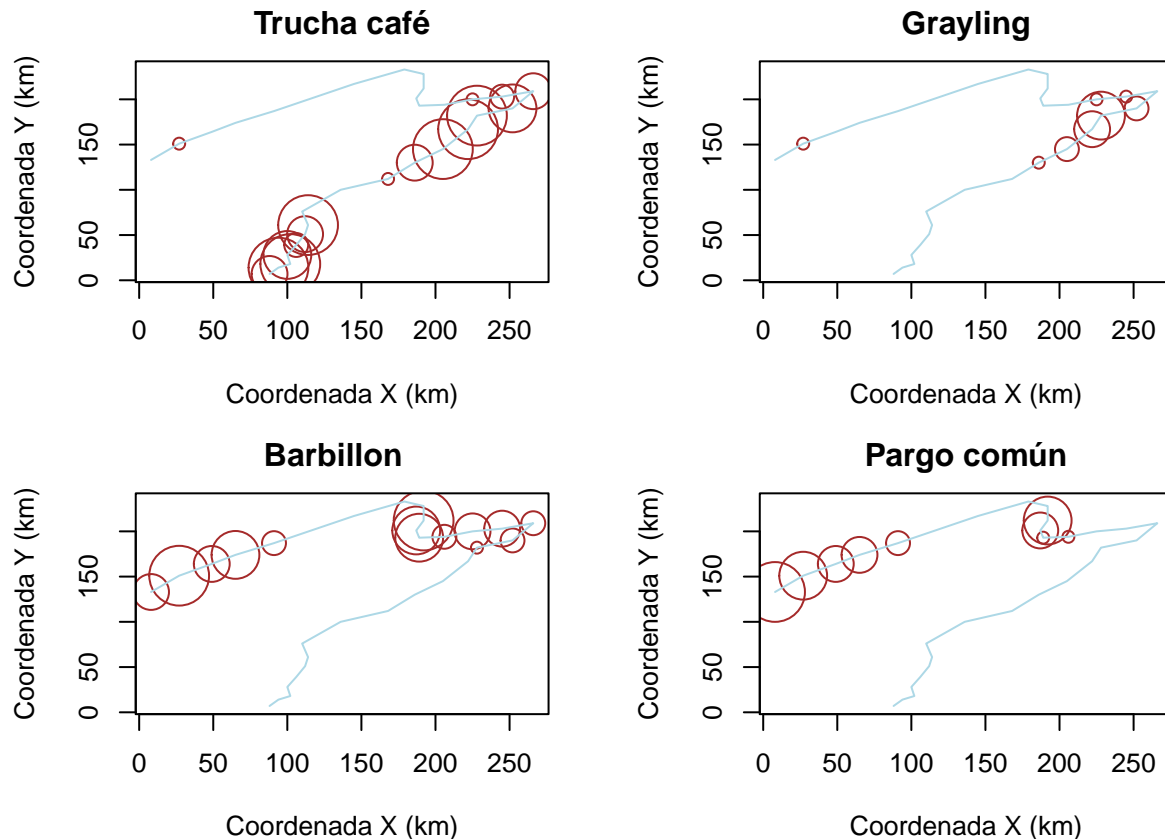


Fig. 3 Mapa de burbujas de abundancia para cuatro especies de peces

Una información importante es determinar la ocurrencia de las especies en sitios de muestreo. Es decir, lo que queremos responder es: En cuántos sitios de muestreo cada una de las especies de peces aparece?. Aquí vamos a calcular las frecuencias relativas de cada especie y la graficaremos histogramas.

```
# Comparar el número de ocurrencias de las especies
# *****
# 1. Calcular el número de sitios donde cada especie esta presente.
# pista: para sumar por columnas se usa la función apply(), la opción MARGIN se coloca en 2 (ver ?apply)
spe.pres <- apply(spe>0,2,sum)
# 2. Ordenar los resultados en modo creciente
sort(spe.pres)

## PCH CHA OMB BLA BCO BBO TOX BOU ROT ANG HOT SPI CAR GRE PSO BAR ABL PER
## 7 8 8 8 9 10 11 11 11 11 12 12 12 12 13 14 14 15
## TRU TAN VAN BRO GAR VAI GOU LOC CHE
## 17 17 18 18 18 20 20 24 25

# 3. Usar porcentaje de frecuencias
spe.relf <- 100*spe.pres/nrow(spe)
# 4 Plotear los histogramas
# Dividimos la ventana gráfica en 2 ventanas horizontales
par(mfrow=c(1,2))
hist(spe.pres,main="Ocurrencia de especies",right=FALSE,las=1,
      xlab="No. de ocurrencias",ylab="No. de especies",
      breaks=seq(0,30,by=5),col="bisque")
```

```
hist(spe.relf,main="Frecuencias relativas",right=FALSE,las=1,
     xlab="Frecuencia de ocurrencia",ylab="No. de especies",
     breaks=seq(0,100,by=10),col="bisque")
```

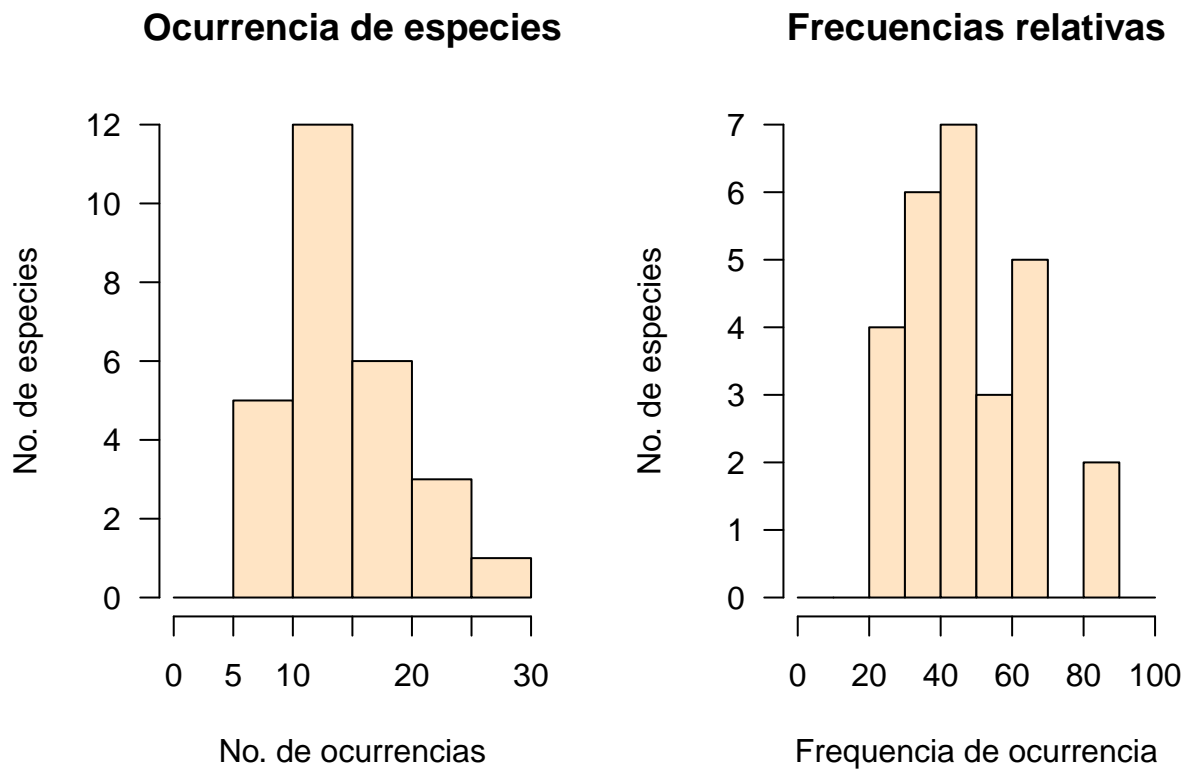


Fig. 4 Histogramas de frecuencia: ocurrencia de las especies y frecuencia relativa para los 30 sitios de muestreo

Ahora podemos comparar los sitios en función de las especies que ahí se encuentran. Es decir, cuántas especies están presentes en cada sitio de muestreo? (riqueza de especies)

```
# Comparar la riqueza de los sitios de muestreo
# *****
# 1. Calcular el número de especies en cada sitio de muestreo
# pista: para sumar por filas se usa la función apply(), la opción MARGIN se coloca en 1 (ver ?apply)
sit.pres <- apply(spe>0,1,sum)
# 2. Ordenar los resultados en modo creciente
sort(sit.pres)

## 8 1 2 23 3 7 9 10 11 12 13 4 24 25 6 14 5 15 16 26 30 17 20 22 27
## 0 1 3 3 4 5 5 6 6 6 6 8 8 8 10 10 11 11 17 21 21 22 22 22 22
## 28 18 19 21 29
## 22 23 23 23 26

# Dividimos la ventana gráfica en 2 ventanas horizontales
par(mfrow=c(1,2))
# 3. Plotear la riqueza de especies vs. la posición de los sitios a lo largo del río
plot(sit.pres,type="s",main="Riqueza de especies vs. \n flujo del río",las=1,
     xlab="Posicion de los sitios a lo largo del río",ylab="Riqueza en especies",col="grey")
text(sit.pres,row.names(spe),cex=0.8,col="red")
# 3. Usamos las coordenadas geográficas para graficar un mapa de burbujas usando la riqueza
plot(spa,main="Mapa de riqueza de especies",pch=21,col="black",bg="brown",cex=4*sit.pres/max(sit.pres),
```

```
lines(spa,col="light blue")
```




Fig. 5 Plots de la riqueza de especies a lo largo del río

Ahora podemos inspeccionar la diversidad ecológica de los sitios de muestreo mediante los índices clásicos de diversidad. Estos índices serán calculados mediante la funciones que proporciona el paquete Vegan.

```
# Calcular los índices de biodiversidad
# *****
# 1. Hay que cargar el paquete vegan
library(vegan)
# 2. Riqueza de especies
N0 <- rowSums(spe>0)
# 3. Entropía de Shannon
H <- diversity(spe,"shannon")
# 4. No. de especies estimada de Shannon (No de Shanon)
N1 <- exp(H)
# 5. Índice de diversidad de Simpson
S <- diversity(spe,"simpson")
# 6. Índice de diversidad de Simpson
N2 <- diversity(spe,"inv")
# 7. Índice de diversidad de Simpson
N2 <- diversity(spe,"inv")
# 8. Índice de homogeneidad o equitabilidad de Pielou
J <- H/log(N0)
# 9. Homogeneidad de Shannon (proporcion de Hill (Hill's ratio))
E1 <- N1/N0
# 9. Homogeneidad de Simpson
E2 <- N2/N0
```

```
div <- data.frame(NO,H,S,N1,N2,E1,E2,J)
head(div)
```

##	NO	H	S	N1	N2	E1	E2	J
## 1	1	0.000000	0.000000	1.000000	1.000000	1.000000	1.000000	NaN
## 2	3	1.077556	0.6527778	2.937493	2.880000	0.9791642	0.9600000	0.9808340
## 3	4	1.263741	0.7031250	3.538634	3.368421	0.8846584	0.8421053	0.9115962
## 4	8	1.882039	0.8253968	6.566883	5.727273	0.8208604	0.7159091	0.9050696
## 5	11	2.329070	0.8961938	10.268387	9.633333	0.9334897	0.8757576	0.9712976
## 6	10	2.108294	0.8571429	8.234184	7.000000	0.8234184	0.7000000	0.9156205

Transformación de los datos y normalización

Hay muchas razones por las cuales los datos pueden ser transformados, sin embargo las razones principales pueden ser:

- Si los descriptores (especies) han sido medidos de diferente manera usando unidades diferentes se pueden usar métodos como por ejemplo: rangos, estandarización a z-scores, escalamientos etc.
- Para hacer las variables normales y estables a su varianza se usan métodos como por ejemplo: raíz cuadrada, raíz cuarta, transformaciones logarítmicas etc.
- Para hacer las relaciones entre los descriptores lineales se puede utilizar: transformaciones logarítmicas
- Modificar los pesos de las variables u objetos, por ejemplo: dar la misma longitud (o norma) a todos los vectores objeto
- Recodificar variables categóricas en variables binarias o contrastes de Helmert.

Para nuestro caso, en el que estamos trabajando con abundancia de las especies, la variable abundancia es dimensionalmente homogénea, es decir que expresa o representa la misma unidad física que estamos midiendo. Además, es una variable cuantitativa (ej., conteos, densidad, cobertura, biovolumen, biomasa, frecuencia, etc.) o semi-cuantitativa (clases), y la cual está restringida a valores positivos o nulos (cero, que representa ausencia). Para este tipo de variables algunas simples transformaciones pueden ser llevadas a cabo con el ánimo de reducir la importancia de observaciones con valores demasiado altos, por ejemplo: raíz cuadrada o cuarta o logaritmo natural de la abundancia + 1 ($\log_1 p$; para mantener la ausencia como cero). En casos extremos, para dar el mismo peso a todos los posibles valores de abundancia (sin importar sus valores), los datos pueden ser transformados en binarios, es decir 1 o 0 para sugerir presencia o ausencia.

En casos de datos sesgados (o distribuciones asimétricas) los datos son a menudo transformados aplicando el logaritmo o la raíz cuadrada. La transformación mediante *raíz cuadrada* es la menos drástica y es usada para normalizar datos que tienen una distribución Poisson, donde la varianza es igual a la media (Fig. 6), mientras que las transformaciones *logarítmicas* se aplican a datos que se apartan de una distribución normal (Fig. 7).

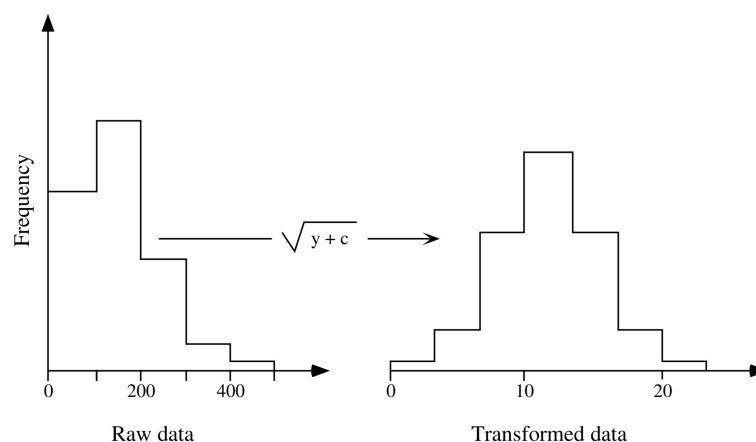


Fig. 6 Transformación raíz cuadrada para normalizar datos con una distribución que tiende a ser Poisson

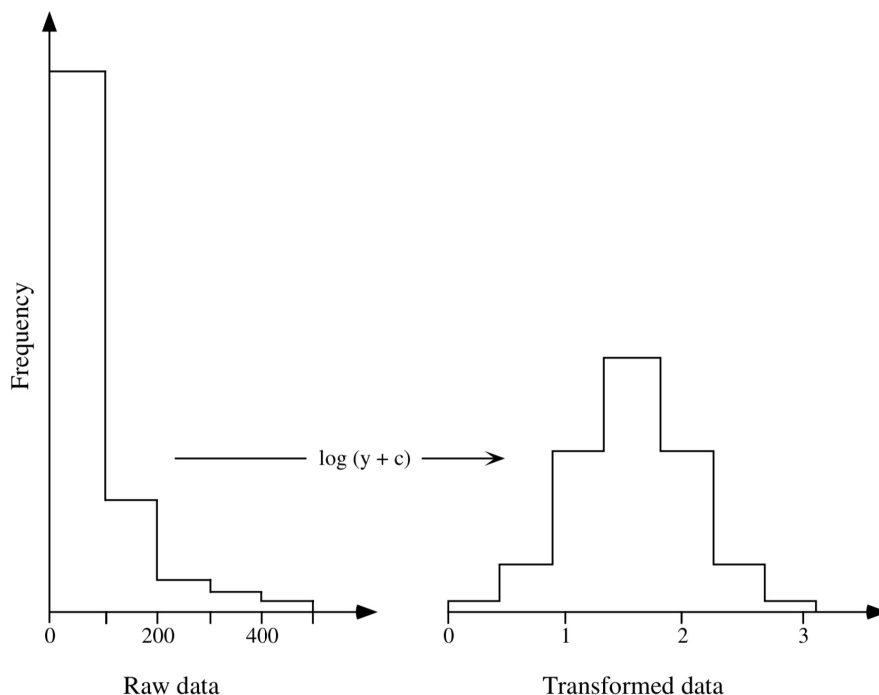


Fig. 7 Transformación logarítmica para normalizar una distribución que tiende a apartarse de una distribución Normal

A este tipo de transformaciones las llamaremos estandarizaciones de los datos ecológicos, y en R se puede usar la función **decostand()** del paquete **Vegan** para hacer dichas estandarizaciones. Lo interesante de **decostand** es que las estandarizaciones no se hacen individualmente sino que se tiene en cuenta los otros valores del set de datos. Estas transformaciones pueden ser echas relativas a los sitios, especies o ambos. La elección de sobre que será relativa la estandarización dependerá del enfoque del análisis, veamos:

```
# Transformación y estandarización de los datos
#####
# Transformaciones simples
# *****
# 1. Presencia ausencia
spe.pa <- decostand(spe,method="pa")
# 2. Raíz cuadrada de los datos
spe.sqrt <- sqrt(spe)
# 3. Logaritmo de la abundancia+1
spe.log1p <- log1p(spe)

# Perfil de las especies
# *****
# Escalamiento de las abundancias con respecto al máximo de la especie
#(abundancia/abund.max.de cada especie)
# Notar que MARGIN=2 (relativo a columnas, en este caso las especies)
spe.scal <- decostand(spe,"max",MARGIN=2)
# 3. Escalar las abundancias dividiendo por el No. total de especies
spe.relsp <- decostand(spe,"total",MARGIN=2)

# Perfil de los sitios
# *****
```

```

# 1. escalar abundancias dividiendolas por el total de los sitios
# (abundancia relativa por sitio)
spe.rel <- decostand(spe,"total",MARGIN=1)
# si el escalamiento funcionó, la suma de las abundancias para cada sitio sera?
# pista: apply(spe.rel,1,sum)

# Hacer la suma de los cuadrados igual a 1 (norma Euclidiana)
spe.norm <- decostand(spe,"normalize")
# verificación de la norma del vector fila (debe ser igual a 1)
norm <- function(x) sqrt(x%*%x)
# pista: apply(spe.norm,1,norm)

# Calcular las frecuencias relativas por filas (perfiles de los sitios)
# Luego le calculamos la raíz cuadrada
# A esto se llama la transformación de Hellinger
spe.hel <- decostand(spe,"hellinger")
# pista: apply(spe.hel,1,norm)

# Estandarización usando ambos, especies y sitios (perfiles dobles)
# *****
# Transformación Chi-cuadrado
spe.chi <- decostand(spe,"chi.square")
# Estandarización de Wisconsin:
# Primero se determina el rango de Las abundancias por la máxima de las especies y
# luego por el total de sitios
spe.wis <- wisconsin(spe)

# Inspeccionemos gráficamente las transformaciones
# *****
par(mfrow=c(2,2),mai=c(0.3,0.3,0.4,0.4))
boxplot(spe$LOC,spe.pa$LOC,spe.sqrt$LOC,spe.log1p$LOC,las=1,
        main="Transformaciones simples",
        names=c("Crudos","Bin.","R.Cuad.","Log."),col="bisque")
boxplot(spe.scal$LOC,spe.rels$LOC,las=1,
        main="Estandarización por especies",
        names=c("Max","total"),col="lightgreen")
boxplot(spe.hel$LOC,spe.rel$LOC,spe.norm$LOC,las=1,
        main="Estandarización por sitios",
        names=c("Hellinger","Total","EucNorm"),col="lightblue")
boxplot(spe.chi$LOC,spe.wis$LOC,las=1,
        main="Doble estandarización (especies/sitios)",
        names=c("Chi-Cuadrado","Wisconsin"),col="orange")

```




Fig. 8 Diagramas de caja de las transformaciones comunes echas a las abundancias de las especies. Como ejemplo, los datos plotados pertenecen al espécimen **LOC** que hace referencia a la especie *Nemacheilus barbatulus* (Stone Loach)

También podemos observar estas transformaciones a lo largo del río:

```
# Inspeccionemos gráficamente las transformaciones a lo largo del río
# *****
par(mfrow=c(2,2),mai=c(0.7,0.7,0.4,0.4))
plot(env$das,spe$TRU,type="l",col=4,main="Datos crudos",
      xlab="Distancia de la fuente (km)",ylab="Ab. crudas")
lines(env$das,spe$OMB,col=3)
lines(env$das,spe$BAR,col="orange")
lines(env$das,spe$BCO,col=2)
lines(env$das,spe$LOC,col=1,lty="dotted")

plot(env$das,spe.scal$TRU,type="l",col=4,main="Perfil por especies",
      xlab="Distancia de la fuente (km)",ylab="Ab.Es. (Max)")
lines(env$das,spe.scal$OMB,col=3)
lines(env$das,spe.scal$BAR,col="orange")
lines(env$das,spe.scal$BCO,col=2)
lines(env$das,spe.scal$LOC,col=1,lty="dotted")

plot(env$das,spe.hel$TRU,type="l",col=4,main="Perfil por sitios (Hellinger)",
      xlab="Distancia de la fuente (km)",ylab="Ab.Es. (Hellinger)")
lines(env$das,spe.hel$OMB,col=3)
lines(env$das,spe.hel$BAR,col="orange")
lines(env$das,spe.hel$BCO,col=2)
```

```
lines(env$das,spe.hel$LOC,col=1,lty="dotted")

plot(env$das,spe.chi$TRU,type="l",col=4,main="Perfil doubles (Chi-cuadrado)",
      xlab="Distancia de la fuente (km)",ylab="Ab.Es. (Chi-cuadrado)")
lines(env$das,spe.chi$OMB,col=3)
lines(env$das,spe.chi$BAR,col="orange")
lines(env$das,spe.chi$BCO,col=2)
lines(env$das,spe.chi$LOC,col=1,lty="dotted")
legend("topright",c("Trucha cafe","Grayling","Barbillon","Pargo","Stone Loach"),
      col=c(4,3,"orange",2,1),lty=c(rep(1,4),3),cex=0.8)
```




Fig. 9 Diagramas de las transformaciones a lo largo del río usando 5 especies de peces

Qué similitudes y/o diferencias observamos en estos perfiles?

Datos ambientales

Una vez hemos explorado los datos de abundancia de especies, es tiempo de explorar los datos medioambientales colectados de los sitios de muestreo. Todos éstos datos están almacenados en el objeto **env** que creamos al principio al importar el archivo que contenía dicha información. Lo primero que podemos hacer es usar la función **summary()** (pista: *summary(env)*) para explorar los datos y notar que tan diferentes son con respecto a los datos de abundancia de las especies.

A continuación, vamos a dibujar sobre el mapa del río algunas de las variables medioambientales primero como mapas de burbujas (**Fig. 10**) y luego en plots individuales siguiendo su cambio a lo largo del flujo del río (**Fig. 11**). Dado que el objeto **env** presenta las variables de acuerdo al código dado por Verneauux, en la **Tabla 1** pueden ver su decodificación y unidades utilizadas para la medición.

Tabla 1 Variables medioambientales de los datos del rio Doubs.

Variable	Codigo	Unidades
Distancia de la fuente	das	km
Altitud	alt	msnm
Pendiente	pen	grad
Media mínima de descarga	deb	m3/s
pH del agua	pH	-
Concentración de Ca (dureza)	dur	mg/L
Concentración de P	pho	mg/L
Concentración de nitratos (NO3)	nit	mg/L
Concentración de armonio (NH4)	amm	mg/L
Oxígeno disuelto	oxy	mg/L
Demanda de oxígeno biológico	duo	mg/L

```
# Mapa de burbujas de las variables medioambientales
# *****
par(mfrow=c(2,2),mai=c(0.7,0.7,0.4,0.4),mar=c(4,4,2,1))
plot(spa,main="Altitud",pch=21,col="black",bg="red",cex=5*env$alt/max(env$alt),
     xlab="X",ylab="Y")
lines(spa,col="light blue")
plot(spa,main="Descarga",pch=21,col="black",bg="blue",cex=5*env$deb/max(env$deb),
     xlab="X",ylab="Y")
lines(spa,col="light blue")
plot(spa,main="Oxígeno",pch=21,col="black",bg="green3",cex=5*env$oxy/max(env$oxy),
     xlab="X",ylab="Y")
lines(spa,col="light blue")
plot(spa,main="Nitratos",pch=21,col="black",bg="brown",cex=5*env$nit/max(env$nit),
     xlab="X",ylab="Y")
lines(spa,col="light blue")
```

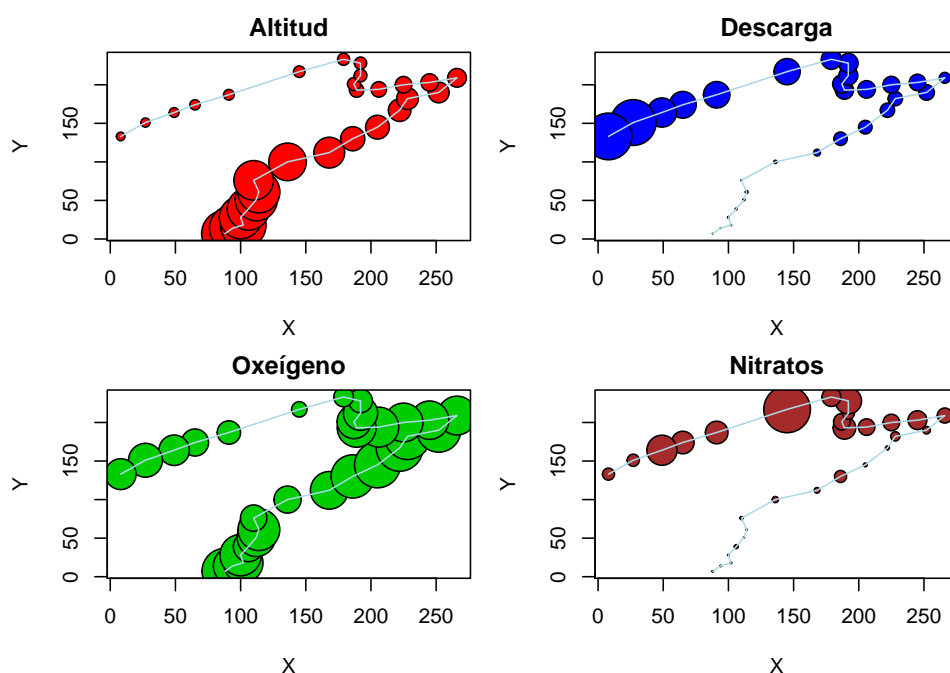


Fig. 10 Mapa de burbujas de cuatro variables medioambientales

```
# Plot de lienas
# *****
par(mfrow=c(2,2),mai=c(0.7,0.7,0.4,0.4),mar=c(4,4,2,1))
plot(env$das,env$alt,type="l",xlab="Distancia desde la fuente (km)",ylab="Altitud (m)",
     col="red",main="Altitud")
plot(env$das,env$deb,type="l",xlab="Distancia desde la fuente (km)",ylab="Descarga (m3/s)",
     col="blue",main="Descarga")
plot(env$das,env$oxy,type="l",xlab="Distancia desde la fuente (km)",ylab="Oxígeno (mg/L)",
     col="green3",main="Oxígeno")
plot(env$das,env$nit,type="l",xlab="Distancia desde la fuente (km)",ylab="Nitratos (mg/L)",
     col="brown",main="Nitratos")
```




Fig. 11 Plot (línea) de cuatro variables medioambientales

También podemos explorar las relaciones pareadas entre las variables medioambientales. Para esto la función de R **pairs()** en un contexto gráfico es muy poderosa. Esta función dibuja una matriz de “scatter plots” en los que se grafican comparaciones pareadas entre variables (**Fig. 12**). Adicionalmente podemos adicionar una línea de tendencia (LOWESS) y un histograma de cada variable en la diagonal de la matriz, la cual muestre la distribución de frecuencia de los valores que toma cada una de las variables. Para generar este gráfico usaremos un script de Francois Gillet.

```
# scatter plot de todas las comparaciones pareadas de las variables ambientales
# *****
# Cargar funciones adicionales a partir del script de Francois Gillet
source("../panelutils.R")
par(mfrow=c(1,1),pty="m")
pairs(env,panel=panel.smooth,diag.panel=panel.hist,main="Plots pareados con histogramas y líneas de ten
```

Plots pareados con histogramas y líneas de tendencia

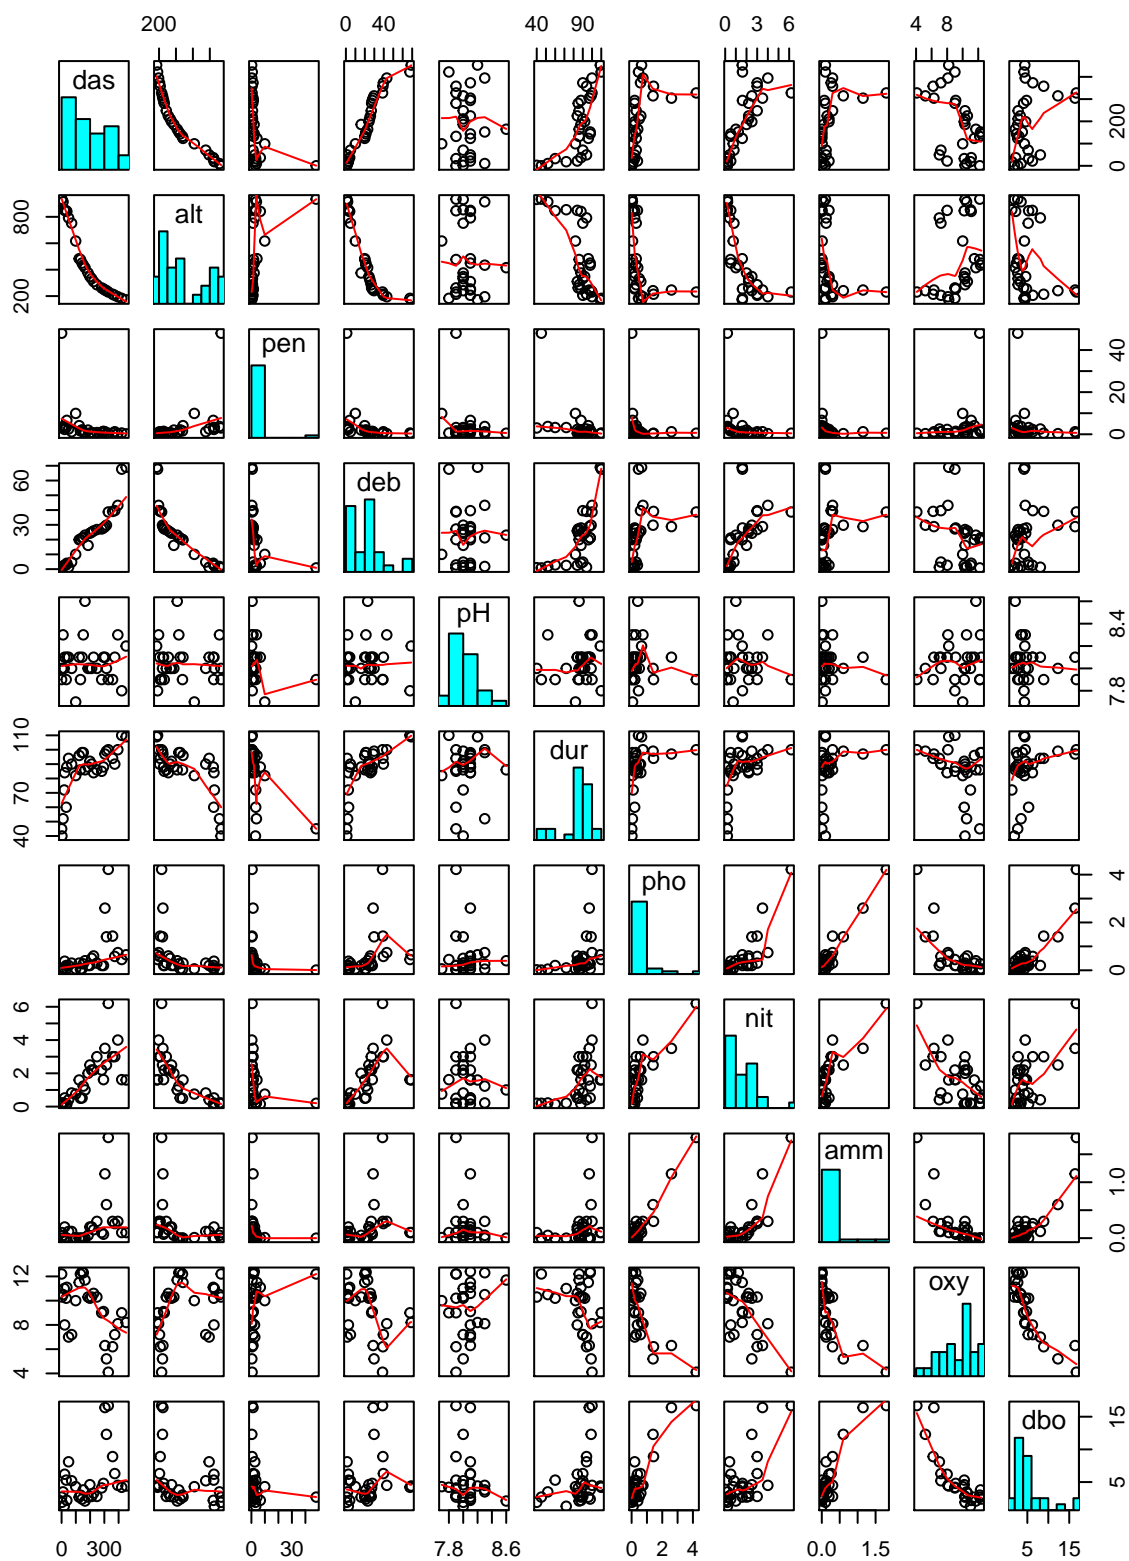


Fig. 12 Scatter plots entre los pares de las variables medioambientales con líneas de tendencia (LOWESS) e histogramas

Podemos usar transformaciones simples, tales transformación logarítmica para mejorar la distribución de algunas variables y acercarnos más a una distribución Normal. Adicionalmente, dado que estas variables son de dimensiones heterogéneas, es decir que se expresan en diferentes unidades y escalas, los análisis estadísticos futuros requieran que ellas sean estandarizadas a una media 0 y varianza 1 (Normalidad). Estas variables centradas y escaladas se llamarán “z-scores”. Miremos como se pueden llevar a cabo dichas transformaciones y estandarizaciones con un ejemplo (**Fig.13**).

```
# Transformaciones simples a las variables medioambientales
# *****
# Transformacion Log. de la variable "pendiente" (y=ln(x))
par(mfrow=c(2,2),mai=c(0.7,0.7,0.4,0.4))
hist(env$pen,col="bisque",right=FALSE,main="Histograma de env$pen")
hist(log(env$pen),col="light green",right=FALSE,main="Histograma de ln(env$pen)")
boxplot(env$pen,col="bisque",main="Boxplot de env$pen",ylab="env$pen")
boxplot(log(env$pen),col="bisque",main="Boxplot de ln(env$pen)",ylab="ln(env$pen)")
```

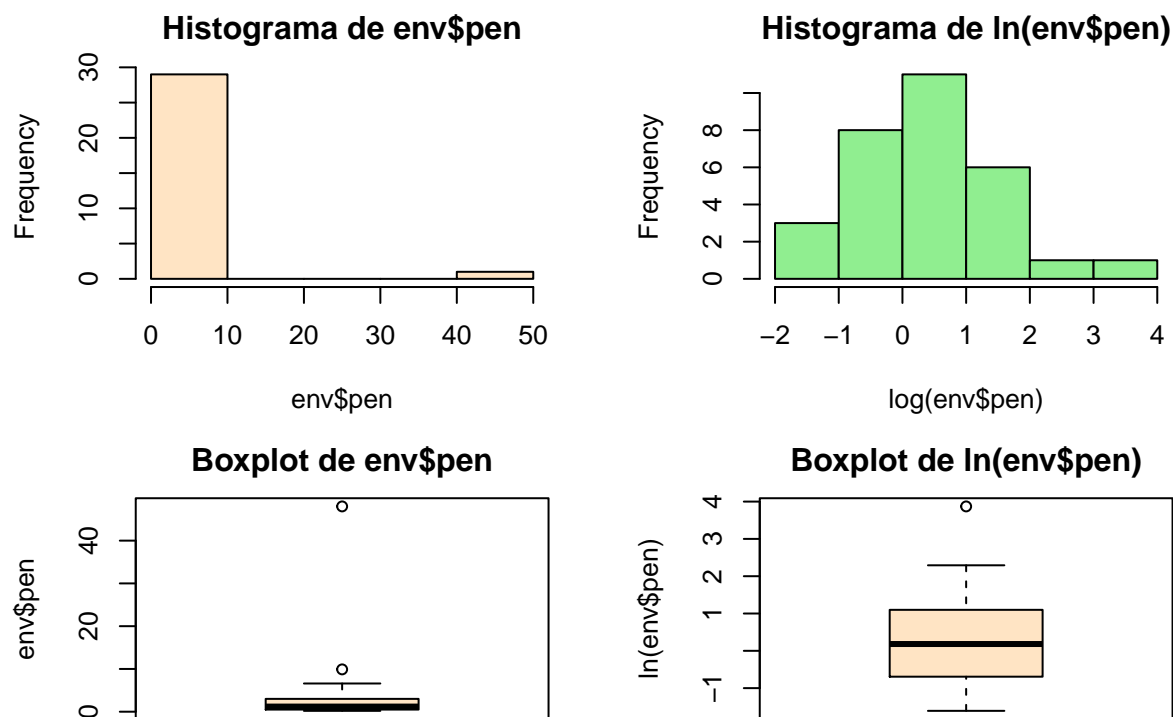


Fig. 13 Histogramas y boxplots de datos no transformados (*izq.*) y datos log-transformados (*derecha*) para la variable **pen** (pendiente)

```
# Estandarización de todas las variables medioambientales
# *****
env.z <- decostand(env,"standardize")
head(apply(env.z,2,mean),n=5)
```

```
##          das          alt          pen          deb          pH
## 1.000429e-16 1.814232e-18 -1.659010e-17 1.233099e-17 -4.096709e-15
```

```
apply(env.z,2,sd)
```

```
## das alt pen deb  pH dur pho nit amm oxy dbo
##   1   1   1   1   1   1   1   1   1   1   1
```

Cómo son las distribuciones de los datos estandarizados vs. los datos crudos?